

Adaptive Neural Graph (ANG)

Wanneer betaalt structurele plasticiteit zich terug? Een gecontroleerde grens, een functionele geheugenmaat en een oorzaak die is getoetst

Frank Jacobs

Correspondentie: frljacobs@gmail.com

Preprint, versie 3.0 · 18 september 2026 · niet peer-reviewed

Bij dit onderzoek is een generatief AI-hulpmiddel gebruikt, en wel in aanzienlijke mate. Wat het precies heeft gedaan staat in de verklaring achterin; die verklaring hoort bij het werk en niet in de kleine lettertjes.

Samenvatting

Wij beschrijven de Adaptive Neural Graph (ANG): een neurale rekenmodel waarin de topologie geen vaste lagen kent maar een gerichte graaf is die zichzelf tijdens het leren herstructureert. Elke knoop draagt een soort die bepaalt welke verbindingen zijn toegestaan — invoer, worker, reflex en geheugen — en die soort ligt niet vast: er kunnen neuronen bijgroeien, zij komen neutraal binnen, en zij krijgen een soort toegewezen op grond van de bedrading die zij feitelijk hebben ontwikkeld. Leren gebeurt zonder backpropagation. De uitvoerknoppen vormen een Bernoulli-beleid waarvan de score-functie exact bekend is; voor de verborgen knopen wordt de gradiënt geschat met node-perturbatie, uit het verschil tussen een schone en een verstoorde doorrekening van dezelfde tijdstep. De afwijking van de beloning ten opzichte van een lopende basislijn moduleert een eligibility trace. Drie begrenzings — een maximale stap per keer, een damping die toeneemt naarmate een gewicht zijn plafond nadert, en een vervaging per poging — zorgen dat verbindingen geleidelijk ontstaan, versterken en verdwijnen in plaats van abrupt. Dit document beschrijft het model, de leerregel, de structurele plasticiteit en de meetinstrumenten volledig, met een referentiemeting over zestien onafhankelijke breinzaden op een vaste benchmarkset van vijfhonderd werelden, en een numerieke controle van de leerregel zelf. Die controle laat zien dat de exacte score-functie voor de uitvoerknoppen de gradiënt nauwkeurig volgt, dat de node-perturbatieschatter de goede richting aanwijst maar veel ruwer, en dat de twee delen van de update niet op dezelfde schaal staan. Een basislijnreeks met dezelfde leerregel op een vaste gelaagde topologie scoort binnen de meetruis gelijk aan de graaf: op deze taak is de prestatie toe te schrijven aan de leerregel en niet aan de structuur. Het enige structurele effect dat boven de ruis uitkomt is padlengte, die bij propagatiediepte één samenvalt met reactietijd. Een tweede reeks houdt de topologie vast en wisselt alleen de schatter: op drie vaste netten levert terugpropagatie meer dan twintig procentpunt op ten opzichte van node-perturbatie, en zij bereikt de score van de graaf met ongeveer een tiende van de parameters en enkele procenten van het rekenwerk. De rekenkosten worden daarbij in vier gescheiden grootheden gerapporteerd, omdat sample-efficiëntie, rekenefficiëntie, wandkloktijd en inferentiekosten zelden samenvallen. Een ablatiereeks van tien condities, elk met een controle per run dat het weggelaten mechanisme werkelijk uit stond en met een Holm-correctie over de familie vergelijkingen, wijst geen enkel afzonderlijk structureel mechanisme aan dat op deze taak aantoonbaar bijdraagt. Omdat een taak waarin het doel altijd zichtbaar is per constructie niets te onthouden geeft, wordt de waarneembaarheid vervolgens als as gevarieerd: het doel is tien spelstappen te zien en daarna een instelbaar aantal stappen niet. Naast de prestatie staat een functionele geheugenmaat die niet aan de neuronsoorten van dit model hangt en op elke architectuur te meten is: dezelfde getrainde agent speelt dezelfde wereld twee keer, één keer met en één keer zonder dat hij het doel ooit gezien heeft, en de horizon is het aantal stappen dat de eerste de tweede blijft verslaan op koers. Wat die as oplevert staat in sectie 10.8 en het is geen bevestiging van de hypothese waarmee dit werk begon. Ten slotte wordt de laatste aanspraak gemeten die een vaste architectuur principieel niet kan waarmaken: één doorlopend leven waarin de omgeving twee keer omslaat zonder waarschuwing. De vrije graaf herstelt daarin niet sneller dan dezelfde graaf met bevroren structuur. Belangrijker dan dat negatieve resultaat is de oorzaak, want die is aanwijsbaar: de herstructurering piekt niet na een omslag maar loopt op een vaste klok, en waar zij wél op een signaal reageert is dat de stagnatie van het eigen leren en niet een verandering in de omgeving. Die oorzaak wordt vervolgens niet alleen aangewezen maar ook weggenomen: de vaste periode maakt plaats voor een detector op de invoerstatistiek, die de terugslag binnen een handvol pogingen ziet en daar vele malen

intensiever verbouwt dan elders, en de proef wordt onveranderd opnieuw gedraaid. Het herstel verandert er niet van, ook niet tegen een klok met precies dezelfde hoeveelheid herstructurering. De negatieve bevinding is daarmee niet aan die ene ontwerpkeuze toe te schrijven, en de conclusie rust op een getoetste oorzaak in plaats van op een aangewezen correlatie. Een tweede taak, gebouwd om de ene druk te toetsen waaronder capaciteit bijbouwen iets kán opleveren — een groeiend aantal regels met tijdschalen van één tot zeventig tikken — bleek voor geen enkele architectuur te leren: ook een recurrent net met terugpropagatie door de tijd, dat hiervoor gebouwd en numeriek gecontroleerd is, leert geen enkele regel die geheugen vraagt. Onderweg bleek de score van die taak twee keer te misleiden, telkens door een speler die precies één stap slimmer was dan de vorige; de uiteindelijke maat (Youdens J per regel) zet elke strategie die niet op de voorwaarde let op nul.

Trefwoorden: zelfstructurende netwerken · reward-gemoduleerde plasticiteit · node-perturbatie · beleidsgradiënt · structurele plasticiteit · interpreteerbaarheid · deels waarneembare omgevingen · negatieve resultaten

1 Inleiding

1.1 Waarom geen lagen

Het gangbare neurale netwerk is een gestapelde functie: de invoer gaat door laag één, het resultaat door laag twee, enzovoort tot de uitvoer. Die vorm is geen eigenschap van zenuwstelsels maar een rekenkundige keuze. Zij maakt de voorwaartse berekening een reeks matrixvermenigvuldigingen en de gradiënt een nette toepassing van de kettingregel. Daar staan twee aannames tegenover die zelden expliciet worden gemaakt. Ten eerste kost elke berekening evenveel stappen: de weg van invoer naar uitvoer is voor elk signaal precies zo lang als het netwerk diep is. Ten tweede stroomt informatie maar één kant op.

Een biologisch zenuwstelsel doet geen van beide. Een reflexboog loopt in twee synapsen van zintuig naar spier, terwijl een afweging tientallen stappen door de cortex maakt; terugkoppeling is er eerder regel dan uitzondering. Dat verschil is niet alleen anatomisch interessant. Het bepaalt welke oplossingen een netwerk überhaupt kán vinden: in een gelaagd netwerk bestaat "sneller reageren dan nadenken" niet als optie.

ANG laat de laagstructuur los. Wat overblijft is een gerichte graaf met getypeerde knopen, waarin de enige harde eis is dat elke invoer ergens naartoe gaat en elke uitvoer ergens vandaan komt. Alles daarbinnen — hoeveel verbindingen een neuron heeft, hoe lang het pad van zintuig naar knop is, of er lussen zijn, en zelfs *welke soort* een neuron is — is uitkomst van het leerproces in plaats van invoer ervan.

1.2 Wat wij willen kunnen aflezen

De vraag achter dit werk is niet in de eerste plaats hoe goed het model presteert, maar welke structuur er ontstaat. Dat komt voort uit een praktisch probleem: van een te klein of slecht getraind netwerk wil je kunnen zien *wáárom* het faalt, niet alleen *dát* het faalt. Elk onderdeel van ANG is daarom zo gekozen dat het achteraf afleesbaar is. Hoeveel stappen heeft een signaal nodig van zintuig naar knop? Hoeveel terugkoppellussen zijn er gevormd? Welke van de zintuigen worden feitelijk genegeerd? Welke neuronen doen niet mee? Sectie 6 formaliseert die maten.

1.3 Bijdragen

- Een **getypeerd grafenmodel** met formele toelaatbaarheidsregels per soort, waaronder een reflexsoort die de klassieke boog zintuig → sensorisch neuron → actuator afdwingt, en een geheugensoort met een verplichte zelfverbinding.
- Een **leerregel zonder backpropagation** die werkt in aanwezigheid van cykels en discrete, gelote acties: een exacte score-functie voor de uitvoerknopen, node-perturbatie voor de verborgen

knopen, en een lopende basislijn die voorkomt dat een altijd-positieve beloning simpelweg alles versterkt.

- **Structurele plasticiteit inclusief soorttoewijzing**, geformuleerd als een kostenminimalisatie over de toegestane soorten: een neuron krijgt de soort die het, gemeten aan zijn eigen bedrading, al feitelijk is.
- **Een verzameling structuurmaten** waarmee de gevormde topologie meetbaar wordt gemaakt: kortste pad, lussen via sterk samenhangende componenten, reflexbogen, deelnemende neuronen en sensorinvloed.
- **Een volledige implementatie** zonder externe afhankelijkheden, die het netwerk tijdens het leren live in beeld brengt en elke run met alle instellingen en de volledige eindstructuur wegschrijft.

1.4 Verwant werk

ANG ligt op het kruispunt van vijf onderzoeksrichtingen. Geen ervan dekt het model, maar samen bakenen zij het af.

Willekeurig bedrade netwerken

Xie et al. [14] lieten zien dat netwerken waarvan de bedrading door een grafengenerator wordt bepaald — Erdős–Rényi, Watts–Strogatz, Barabási–Albert — op ImageNet kunnen wedijveren met met de hand ontworpen architecturen; You et al. [15] onderzochten systematisch welke graafeigenschappen met prestatie samenhangen. In beide gevallen wordt de graaf één keer getrokken en daarna bevroren: er worden uitsluitend gewichten getraind. In ANG blijft de graaf veranderen zolang er geleerd wordt.

Neuro-evolutie

NEAT [11] laat topologie ontstaan door selectie over een populatie, met mutaties die knopen en verbindingen toevoegen. ANG bereikt iets vergelijkbaars binnen één individu en tijdens zijn leven: er is geen populatie, geen generatie en geen selectie, alleen ervaring.

Reservoir computing

Echo-state-netwerken en liquid state machines [7, 8] gebruiken een vaste, willekeurige recurrente graaf en trainen uitsluitend een uitleeslaag. ANG deelt de willekeurige recurrente graaf, maar traint alle verbindingen en laat de graaf zelf veranderen.

Leerregels zonder backpropagation

De leerregel combineert de score-functieschatter van REINFORCE [13] voor de discrete acties met node-perturbatie [3, 10] voor de verborgen knopen, in een vorm met eligibility traces die aansluit bij reward-gemoduleerde plasticiteit [4, 6] en bij $TD(\lambda)$ [12]. In de terminologie van die literatuur is het resultaat een reward-gemoduleerde Hebbiaanse regel; de afleiding in 3.3 en 3.4 laat zien dat diezelfde regel tegelijk een gradiëntschatter is. De dichtheidsbeloning in sectie 5 is potentiaal-gebaseerd in de zin van Ng, Harada en Russell [9], zodat zij het optimale beleid niet verandert.

Structurele plasticiteit

In de neurowetenschap is het onderscheid tussen synaptische en structurele plasticiteit gangbaar: bij de eerste verandert het gewicht van een bestaande verbinding, bij de tweede ontstaat of verdwijnt de verbinding zelf [2, 5]. ANG doet beide, en dat is het scherpste verschil met gangbare deep learning. In neuromorfe systemen is die combinatie eerder gerealiseerd, met herbedrading naast een leerregel voor de overgebleven verbindingen [1].

En hoe verhoudt dit zich tot grafenneurale netwerken?

Een GNN rekent over een graaf die als *data* gegeven is: knopen wisselen berichten uit met hun burens volgens een vaste structuur. In ANG is de graaf geen invoer maar *toestand* — hij is onderdeel van wat

er geleerd wordt, en hij is aan het einde van een training een andere dan aan het begin. Dat is geen gradueel maar een categorisch verschil, en het is de reden dat de meetinstrumenten in sectie 6 nodig zijn: bij een GNN weet je de structuur al, bij ANG moet je haar achteraf vaststellen.

2 Het model

2.1 Graaf, knopen en soorten

Een ANG is een gerichte graaf met getypeerde knopen:

$$V = I \cup O \cup H, \quad |I| = 16, \quad |O| = 4, \quad E \subseteq V \times V \quad (1)$$

waarin I de invoerknopen zijn (in de hier beschreven instantie zestien zintuigwaarden), O de uitvoerknopen (vier knopen) en H de wolk ertussen. Elke knoop draagt een soort:

$$\kappa : V \rightarrow K, \quad K = \{\text{in, sens, work, refl, mem, neut, out}\} \quad (2)$$

De soorten in en out horen bij de vaste invoer- en uitvoerknopen. De vier soorten die de gebruiker kan inschakelen zijn sens (invoer-neuron), work (worker), refl (reflex of instinct) en mem (geheugen). De soort neut (neutraal) is een tijdelijke toestand van een pas gegroeid of losgeraakt neuron dat nog geen soort heeft gekregen; sectie 4.4 beschrijft hoe die toewijzing verloopt.

2.2 Toelaatbaarheid

Niet elke verbinding mag. Een relatie L over soortenparen bepaalt welke bogen bestaan mogen:


$$(a, b) \in E \Rightarrow L(\kappa(a), \kappa(b)) = 1 \quad \text{en} \quad a = b \Rightarrow \kappa(a) = \text{mem} \quad (3)$$

De regels luiden, in volgorde van toepassing:

- Naar een invoerknoop gaat nooit een verbinding toe; uit een uitvoerknoop komt nooit een verbinding vandaan.
- Een invoer-neuron accepteert als ingang uitsluitend invoerknopen. Zijn uitgang is vrij.
- Een reflex-neuron accepteert als ingang uitsluitend invoer-neuronen en heeft als uitgang uitsluitend uitvoerknopen. Er is voor deze soort geen andere mogelijkheid.
- Een invoerknoop mag niet rechtstreeks aan een uitvoerknoop hangen: elk signaal passeert minstens één neuron.
- Een zelfverbinding is uitsluitend toegestaan voor een geheugen-neuron, en is voor die soort verplicht.
- Worker-, geheugen- en neutrale neuronnen mogen voor het overige alles met alles.

De reflexregel is bewust de meest beperkende. Zij dwingt de klassieke reflexboog af: *receptor* → *sensorisch neuron* → *interneuron* → *effector*. Er is voor deze soort geen andere mogelijkheid, en dat maakt achteraf meetbaar of een brein zo'n boog heeft gevormd of alles door de wolk laat lopen.

Daarbij hoort een waarschuwing die pas zichtbaar wordt als men de padlengtes daadwerkelijk meet. Standaard mag een worker-neuron *wel* rechtstreeks aan een invoerknoop hangen. Het pad invoer → worker → knop is dan twee bogen, terwijl de reflexboog er drie telt — de reflex is dus niet de kortste maar juist de langere weg, en verliest daardoor systematisch de concurrentie om de motoraansturing. Wie wil dat de reflexboog werkelijk het kortste pad is, zet de optie aan die invoerknopen uitsluitend aan invoer-neuronen laat hangen; dan is elk pad drie bogen lang. Die keuze heeft een prijs: alle zestien zintuigen moeten dan door een handvol invoer-neuronen, en dat is een informatie-flessenhals die het leren aanzienlijk moeilijker maakt. Beide varianten zijn instelbaar, en het verschil ertussen is een van de metingen die sectie 10 voorstelt.



Figuur 1 — De toegestane verbindingen tussen de knoopsorten. Streepjeslijnen gelden zolang een neuron neutraal is. Er gaat nooit iets naar een invoerknoop toe, nooit iets uit een uitvoerknoop vandaan, en een invoerknoop hangt nooit rechtstreeks aan een knop.

2.3 Invarianten

Vijf eigenschappen gelden op elk moment, en worden na elke herstructurering hersteld:

- **I1** elke invoerknoop heeft uitgraad ≥ 1 ;
- **I2** elke uitvoerknoop heeft ingraad ≥ 1 ;
- **I3** elke boog is toelaatbaar volgens L ;
- **I4** elk geheugen-neuron heeft zijn zelfverbinding;
- **I5** de worker-neuronen vormen de meerderheid van de toegewezen neuronen, en elke soort blijft binnen de door de gebruiker opgegeven onder- en bovengrens (vergelijking 28).

I1 en I2 zijn de enige eis die aan de bedrading wordt gesteld; er is geen minimum of maximum aantal verbindingen per neuron. I5 is een ontwerpeis: de wolk moet in meerderheid uit neuronen bestaan die alles mogen, zodat de gespecialiseerde soorten uitzonderingen blijven en niet de structuur gaan dicteren.

2.4 Toestandsdynamiek

De toestand van het netwerk op tijdstip t is de vector van activaties x . Eén spelstap bestaat uit P propagatiestappen. Bij elke propagatiestap wordt eerst voor elke niet-invoerknoop de netto-invoer bepaald,

$$u_j^{(s)} = b_j + \sum_{i: (i,j) \in E} w_{ij} x_i^{(s-1)} \quad (4)$$

en vervolgens de nieuwe activatie:

$$x_j^{(s)} = \tanh(u_j^{(s)} + \xi_j), \quad \xi_j \sim \mathcal{U}(-\sigma_h, \sigma_h) \quad (5)$$

met ξ een uniforme exploratieruis. Geheugen-neuronen zijn lekkende integratoren, zodat zij hun waarde over de tijd vasthouden:

$$x_j^{(s)} = (1 - \alpha) x_j^{(s-1)} + \alpha \tanh(u_j^{(s)} + \xi_j) \quad (\kappa(j) = \text{mem}) \quad (6)$$

De actualisering is synchroon: alle knopen lezen de toestand van de vorige propagatiestap. Daardoor is een cyclus geen probleem — een zelfverbinding of een terugkoppeling door de wolk is gewoon een bijdrage aan de netto-invoer van de volgende stap. De parameter P bepaalt hoe ver een signaal binnen

één spelstap door de wolk reist. Bij $P = 1$ kost elke boog een tijdstap, en is een korte reflexboog daadwerkelijk sneller dan een lange omweg; bij hogere P vervaagt dat verschil.

2.5 Actieselectie

De vier uitvoerknoppen zijn geen deterministische drempels maar kansen. Dat is geen esthetische keuze: het maakt het beleid differentieerbaar in zijn parameters en levert daarmee een exacte gradiënt (sectie 3.3).

$$p_k = \sigma\left(\frac{u_k}{\tau}\right), \quad a_k \sim \text{Bernoulli}(p_k), \quad k \in \mathcal{O} \quad (7)$$

waarbij τ een temperatuur is die de scherpte van de beslissing regelt. De vier geloten bits worden vertaald naar een verplaatsing; twee tegelijk levert een diagonaal, alle vier of geen enkele levert stilstand:

$$\Delta \mathbf{q}_t = v \cdot \frac{(a_r - a_l, a_d - a_u)}{\|(a_r - a_l, a_d - a_u)\|} \quad (8)$$

Bij evaluatie zonder leren vervalt de loting en geldt $a_k = 1$ dan en slechts dan als $p_k > 1/2$, wat onafhankelijk is van τ .

3 Leren zonder backpropagation

3.1 Waarom backpropagation hier niet past

Drie eigenschappen van ANG sluiten de gebruikelijke aanpak uit.

- **De graaf bevat cykels.** Backpropagation vereist een acyclische rekengrafiek. Voor recurrente netwerken bestaat backpropagation-through-time, maar dat vraagt om het uitrollen van de volledige tijdreeks en om een topologie die tijdens die reeks niet verandert.
- **De topologie verandert tijdens het leren.** Verbindingen verdwijnen, komen erbij, en neuronen veranderen van soort. Een vaste rekengrafiek waarop een gradiënt gedefinieerd kan worden, bestaat dus niet.
- **De acties zijn discreet en geloot.** Er is geen doellabel om een fout tegen af te zetten, alleen een beloningssignaal, en de stap van kans naar knopdruk is niet differentieerbaar.

Wat wél kan, is een schatter van de gradiënt van de verwachte opbrengst opbouwen uit grootheden die lokaal aan elke verbinding beschikbaar zijn. Dat is de weg die hier gevolgd wordt.

3.2 Doelfunctie

Wij maximaliseren de verwachte som van beloningen over een poging:

$$J(\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{t=0}^T r_t \right], \quad \theta = \{w_{ij}, b_j\} \quad (9)$$

3.3 De uitvoerknoppen: een exacte score-functie

Omdat de knoppen Bernoulli-variabelen zijn met kans $p_k = \sigma(u_k/\tau)$, is de afgeleide van de log-waarschijnlijkheid van de gekozen actie naar de netto-invoer exact bekend:

$$\frac{\partial}{\partial u_k} \log \pi_\theta(a_k) = a_k - p_k \quad (10)$$

en daarmee, via de kettingregel over één enkele stap, naar het gewicht van een inkomende verbinding:

$$\frac{\partial}{\partial w_{ik}} \log \pi_\theta(a_k) = \frac{1}{\tau} \tilde{x}_i (a_k - p_k) \quad (11)$$

Dit is de klassieke score-functieschatter [12]. De factor $1/\tau$ is een constante schaalfactor die in de leersnelheid wordt opgenomen. Het aantrekkelijke is dat de term $(a_k - p_k)$ precies meet *hoezeer de genomen actie afweek van wat het netwerk gemiddeld zou doen* — en alleen die afwijking is iets waaraan beloning toegeschreven mag worden.

3.4 De wolk: node-perturbatie

Voor de verborgen knopen bestaat zo'n exacte uitdrukking niet. Wij gebruiken node-perturbatie [10, 3]. Elke spelstap wordt twee keer doorerekend vanaf dezelfde begintoestand: één keer zonder ruis en één keer met ruis. Het verschil is per definitie de duw die de exploratie gaf:

$$\delta_j = x_j - \bar{x}_j \quad (12)$$

Omdat de ruis symmetrisch is, geldt $E[\delta] = 0$, en is het product van de activatie vóór de verbinding met de perturbatie erna, gewogen met de beloningsafwijking, een schatter van de gradiënt:

$$E[\tilde{x}_i \delta_j \hat{A}] = c_j \frac{\partial J}{\partial w_{ij}} + \mathcal{O}(\sigma_h^2), \quad c_j > 0 \quad (13)$$

De evenredigheidsconstante is niet één getal voor het hele netwerk. Voor een knoop in de wolk komt zij uit de variantie van de perturbatie en de helling van de overdrachtsfunctie; voor een knop is zij de schaal van de exacte score-functie uit 3.3:

$$c_j \approx \text{Var}(\xi) \phi'(u_j) \quad (j \in \mathcal{H}), \quad c_k = \frac{1}{\tau} \quad (k \in \mathcal{O}), \quad \text{Var}(\xi) = \frac{\sigma_h^2}{3} \quad (37)$$

Dat onderscheid is niet cosmetisch. $\text{Var}(\xi)$ is bij de standaardinstellingen ongeveer $3,7 \cdot 10^{-3}$, dus de twee delen van de update verschillen van nature ruwweg twee ordes in schaal. In de gebruikelijke formulering van node-perturbatie [10, 3] wordt daarvoor gecorrigeerd met een factor $1/\text{Var}(\xi)$; ANG deed dat niet, en sectie 3.11 laat zien wat dat kost. De schatter is verder zuiver op een term van tweede orde in de ruissterkte na. Belangrijker voor de praktijk is dat hij volledig lokaal is: hij vraagt alleen de activatie aan de ene kant van een verbinding en de perturbatie aan de andere. Er is geen pad terug door het netwerk nodig, en dus ook geen acyclische structuur.

3.5 Eligibility traces

Een beloning valt zelden op hetzelfde moment als de actie die haar veroorzaakte. Elke verbinding houdt daarom een spoor bij van haar recente bijdrage:

$$e_{ij}(t) = \lambda e_{ij}(t-1) + (1-\lambda) \tilde{x}_i(t) \delta_j(t), \quad \tilde{x}_i(t) \equiv x_i^{(P-1)}(t) \quad (14)$$

Welke activatie hier aan de presynaptische kant hoort, ligt minder voor de hand dan het lijkt. Een tik bestaat uit P propagatiestappen (vgl. 4), en die worden synchroon uitgevoerd: eerst worden alle netto-invoeren uit de bestaande toestand berekend, pas daarna wordt geschreven. De uitvoer van knoop j in deze tik is dus voortgebracht door de toestand aan het *begin* van de laatste propagatiestap, niet door de toestand die erna in het netwerk staat. Dat is de grootheid $\tilde{x}_i$ in vergelijking 14, en om dezelfde reden ook in 11 en 13. Voor invoerknopen maakt het niets uit — die worden aan het begin van de tik op hun sensorwaarde gezet en veranderen daarna niet meer — maar voor elke verbinding die uit de wolk zelf vertrekt wél, en bij $P > 1$ groeit het verschil.

De normalisatie met $(1-\lambda)$ is niet cosmetisch: zonder die factor groeit het spoor met $1/(1-\lambda)$, waardoor een verandering van λ ongemerkt ook de effectieve leersnelheid verandert. Met de factor erbij blijft de schaal van het spoor gelijk en regelt λ uitsluitend hoe ver terug de beloning wordt uitgesmeerd. Voor de biasterm geldt dezelfde regel met de pre-activatie gelijk aan één.

Hoe gevoelig is het spoor voor de keuze van $\tilde{x}$?

De keuze hierboven is af te leiden uit de dynamiek, maar zij is niet vanzelfsprekend voor wie dit op een ander substraat bouwt: in een asynchrone of hardwarematige uitvoering is "de toestand vóór de laatste propagatiestap" niet zonder meer beschikbaar, en de toestand erna wel. De vraag is dus wat het kost om de verkeerde te nemen. Beide varianten zijn daarom naast elkaar gemeten; in de code is de tweede beschikbaar als ablatie.

maat	toestand ná de stap	toestand vóór de stap	verschil (gepaard)	Mann-Whitney
succes over de laatste 20 pogingen	85.0% ± 5.9	89.2% ± 5.6	+4.2 ± 7.0 pp	p = 0.326
toets op onbekende werelden	68.3% ± 3.0	67.9% ± 4.3	-0.4 ± 3.9 pp	p = 0.931
succes over de hele training	63.3% ± 2.8	63.5% ± 1.9	+0.2 ± 2.2 pp	p = 0.954

12 breinzaden per conditie, 500 pogingen per run, verder identieke instellingen en dezelfde wereldzaden. Op geen van de maten is het verschil groter dan de spreiding tussen zaden. De leerregel is op deze taak dus ongevoelig voor de keuze — wat niet betekent dat zij willekeurig is: de afgeleide term is die waarop de aanspraak van sectie 3.4 rust, en de numerieke controle van sectie 3.11 meet haar en niet de andere. Wie het model op een substraat bouwt waar alleen de toestand ná de stap beschikbaar is, betaalt daar op deze taak echter geen meetbare prijs voor. Beide reeksen staan volledig in experimenten/runs.csv onder de condities trace-oud en trace-nieuw.

De reden dat het verschil zo klein blijft, komt uit de controle van sectie 3.11. Over een losse tik met een willekeurige wolktoestand schelen de twee sporen tientallen procenten, maar in het beloningsgewogen gemiddelde over een hele poging is het verschil 0.7 %: de toestand van de wolk verandert langzaam, dus de activatie van vóór en ná één propagatiestap lijken sterk op elkaar. Bij een snellere dynamiek — een kleinere geheugentraagheid, een grotere P, of een taak met scherpere overgangen — is die marge er niet, en dan is de afgeleide term geen formaliteit meer.

3.6 Basislijn en advantage

Beloning in absolute zin is geen bruikbaar leersignaal. Beweegt de agent consequent in de goede richting, dan is elke beloning positief en zou elke verbinding die actief was versterkt worden — inclusief de verbindingen die niets bijdroegen. Wij trekken daarom een lopende basislijn af:

$$\bar{r}_t = \bar{r}_{t-1} + \beta(r_t - \bar{r}_{t-1}), \quad \beta = 0.02 \quad (15)$$

$$\hat{A}_t = \text{clip}(r_t - \bar{r}_t, -c, c), \quad c = 10 \quad (16)$$

$\hat{A}_t$ is een advantage-schatting: hoeveel beter of slechter deze stap uitpakte dan het brein de laatste tijd gewend was. De begrenzing voorkomt dat één uitschieter — bijvoorbeeld het bereiken van het doel — de gewichten in één keer omgooit. In de ontwikkeling van dit model bleek het weglaten van de basislijn de belangrijkste oorzaak van falen: zonder haar liepen alle gewichten binnen enkele honderden stappen tegen hun plafond aan.

3.7 De begrensde update

De ruwe verandering van een gewicht is het product van leersnelheid, advantage en spoor:

$$\widetilde{\Delta w_{ij}} = \eta_t \hat{A}_t e_{ij} \quad (17)$$

Daarop werken drie begrenzungen, die elk een ontwerpeis afdwingen.

Niet oneindig versterken

Een verandering die een gewicht verder van nul af duwt, wordt gedempt naarmate dat gewicht zijn plafond nadert; een verandering die het naar nul toe brengt niet:

$$\varphi(w, \tilde{\Delta}) = 1 - \frac{|w|}{w_{\max}} \cdot \mathbf{1}[\text{sgn}(\tilde{\Delta}) = \text{sgn}(w)] \quad (18)$$

Niet abrupt

De verandering per stap is hard begrensd, en het gewicht zelf blijft binnen zijn bereik:

$$\Delta w_{ij} = \text{clip}(\varphi \cdot \tilde{\Delta} w_{ij}, -\Delta_{\max}, \Delta_{\max}) \quad (19)$$

$$w_{ij} \leftarrow \text{clip}(w_{ij} + \Delta w_{ij}, -w_{\max}, w_{\max}) \quad (20)$$

De combinatie is belangrijk. De damping alleen zou een gewicht asymptotisch tegen het plafond aan laten kruipen zonder het ooit te bereiken, maar zegt niets over de snelheid; de stapbegrenzing alleen zou een gewicht in een rechte lijn naar zijn plafond laten lopen. Samen leveren zij een verbinding die geleidelijk sterker wordt en daarbij steeds moeilijker nog sterker te maken is.

3.8 Vervaging

Eenmaal per poging zakt elk gewicht een klein stuk terug naar nul:

$$w_{ij} \leftarrow (1 - \rho) w_{ij} \quad (21)$$

Wat niet regelmatig bekrachtigd wordt, verdwijnt daarmee vanzelf, en wordt uiteindelijk gesnoeid (sectie 4.1). De keuze om dit per poging te doen en niet per spelstap is empirisch: bij een paar honderd stappen per poging overheerst een vervaging per stap het leersignaal volledig, en krimpen de gewichten monotoon ongeacht wat het netwerk presteert.

3.9 Exploratieschema

De exploratie loopt gedurende de training terug, maar nooit tot nul:

$$\varepsilon_e = \varepsilon_0 + (\varepsilon_\infty - \varepsilon_0) \min(1, \frac{e}{E}), \quad \varepsilon_\infty = \max(0.3 \varepsilon_0, 0.03) \quad (22)$$

Uit die ene grootheid volgen de drie plekken waar exploratie in het model binnenkomt:

$$\eta_e = \eta_0 \frac{\varepsilon_e}{\varepsilon_0}, \quad \tau_e = 0.40 + 2 \varepsilon_e, \quad \sigma_h = 0.35 \varepsilon_e \quad (23)$$

De ondergrens is essentieel. Zonder exploratie is δ gelijk aan nul, valt het leersignaal weg, terwijl de vervaging en het snoeien doorgaan — een goed getraind netwerk valt dan aan het einde van de training alsnog uit elkaar. Het meeschalen van de leersnelheid met de exploratie houdt de verhouding tussen signaal en aanpassing constant.

3.10 Het algoritme in zijn geheel

Algoritme 1 — leren

```
voor elke poging e = 1 ... E:
  ε ← exploratieschema(e)                                     (22)
  zet de toestand van het netwerk en alle sporen op nul
  voor elke spelstap t = 1 ... T:
    neem waar → invoervector s
    schone doorrekening  $\tilde{x} \leftarrow \text{propagate}(s, \text{ruis} = 0)$ 
    ruisige doorrekening  $x \leftarrow \text{propagate}(s, \text{ruis} = \varepsilon)$ ; bewaar  $\tilde{x}$  = toestand vóór de laatste
  stap
  δ ← x -  $\tilde{x}$                                                  (12)
  voor elke knop k:  $a_k \sim \text{Bernoulli}(p_k)$ ;  $\delta_k \leftarrow a_k - p_k$  (7, 10)
```

```

voer de actie uit → beloning r

$$e_{ij} \leftarrow \lambda e_{ij} + (1-\lambda) \tilde{x}_i \delta_j \quad (14)$$


$$\tilde{A} \leftarrow \text{clip}(r - \tilde{r}, -c, c); \quad \tilde{r} \leftarrow \tilde{r} + \beta(r - \tilde{r}) \quad (15, 16)$$


$$w_{ij} \leftarrow \text{clip}(w_{ij} + \text{clip}(\phi \cdot \eta \tilde{A} e_{ij}, \pm \Delta \max), \pm w \max) \quad (17-20)$$


$$w \leftarrow (1 - \rho) w \quad (21)$$

als e mod K = 0: herstructureer (algoritme 2)


```

3.11 Numerieke controle van de leerregel

De aanspraak van 3.4 — dat de update een schatter van de gradiënt is — was tot nu toe een afleiding en geen meting. Wij toetsen haar op een miniatuur-ANG met vier verborgen knopen en een bevroren topologie, waar de gradiënt nog met de hand na te rekenen is:

$\partial J / \partial w_{ij} \approx (J(w+\epsilon) - J(w-\epsilon)) / 2\epsilon$, met J geschat als de gemiddelde totale beloning over een vast blok pogingen.

Twee dingen maken die schatting bruikbaar. Ten eerste **gemeenschappelijke toevalsgetallen**: elke poging heeft een vaste eigen toevalsgenerator en een vaste wereld, identiek voor elke waarde van w . Zonder die truc verdrinkt het verschil tussen $J(w+\epsilon)$ en $J(w-\epsilon)$ in de ruis van het beleid zelf. Ten tweede een **ijking van de meetlat**: de numerieke gradiënt wordt twee keer berekend op onafhankelijke blokken pogingen. De cosinus tussen die twee helften zegt hoeveel van de gemeten richting signaal is, en dus hoe hoog een cosinus überhaupt kan worden. Bij 800 pogingen per helft is die 0.987; het meetbare plafond ligt daarmee op 1.00. Een cosinus die daar tegenaan zit, is niet meer van een perfecte uitlijning te onderscheiden.



Figuur 2 — De ANG-update tegen de numerieke gradiënt op de miniaturgraaf. Links: per verbinding, met één gemeenschappelijke schaalfactor. De verbindingen naar de knoppen liggen op de diagonaal; de verbindingen naar de wolk liggen plat tegen de nullijn — hun richting klopt wel, hun grootte niet. Rechts: de cosinus als functie van het aantal pogingen waarover de update gemiddeld wordt.

Meetpunt: begin

deel van de update	n	cos met ∇J	schaa factor c	aandeel in $ \Delta w $	aandeel in $ \nabla J $
naar een knop (score-functie)	12	0.99	2	100 %	73 %
naar de wolk (node-perturbatie)	62	0.27	96	1 %	68 %

Over alle verbindingen samen is de cosinus 0.73; schaal men de twee delen apart, dan wordt zij 0.75. De schaalfactor van het wolkeel is 44× die van het knopdeel.

Meetpunt: half getraind

deel van de update	n	cos met ∇J	schaa factor c	aandeel in $ \Delta w $	aandeel in $ \nabla J $
naar een knop (score-functie)	12	0.85	2	100 %	12 %
naar de wolk (node-perturbatie)	62	0.83	608	2 %	99 %

Over alle verbindingen samen is de cosinus 0.12; schaalt men de twee delen apart, dan wordt zij 0.83. De schaalfactor van het wolkeel is 349× die van het knopdeel.

Meetpunt: begin prop=2

deel van de update	n	cos met ∇J	schaa factor c	aandeel in $ \Delta w $	aandeel in $ \nabla J $
naar een knop (score-functie)	12	1.00	2	100 %	71 %
naar de wolk (node-perturbatie)	62	0.36	225	0 %	70 %

Over alle verbindingen samen is de cosinus 0.71; schaalt men de twee delen apart, dan wordt zij 0.75. De schaalfactor van het wolkeel is 105× die van het knopdeel.

Wat de meting zegt

- **De exacte score-functie klopt.** Voor de verbindingen naar de knoppen is de cosinus 0.99 / 0.85 / 1.00 op de drie meetpunten. Bij een meetbaar plafond van 1.00 / 0.99 / 0.99 is dat niet van exact te onderscheiden: vergelijking 11 doet wat zij belooft.
- **Node-perturbatie wijst de goede kant op, maar ruw.** Voor de verbindingen naar de wolk is de cosinus 0.27 / 0.83 / 0.36. Positief en bruikbaar, maar ver van exact — en sterk afhankelijk van het punt in de gewichtsruimte.
- **De twee delen staan niet op dezelfde schaal.** Dit is de belangrijkste uitkomst. Het wolkeel van de update is gemiddeld ongeveer 166× te klein ten opzichte van het knopdeel, wat overeenkomt met de ontbrekende normalisatie $1/\text{Var}(\xi)$ uit vergelijking 37 (≈ 272 bij deze exploratie). Het gevolg is te zien in figuur 2a: met één leersnelheid krijgt de wolk feitelijk nauwelijks een update, terwijl de echte gradiënt daar 68 % / 99 % / 70 % van zijn lengte heeft liggen.
- **De ruis is niet het probleem.** Uit figuur 2b: het gemiddelde over ongeveer dertig pogingen zit al op de eindwaarde. Meer monsters helpen daarna niet meer — wat er dan nog tussen zit is geen variantie maar vertekening.

De keuze van ε stuurt de uitkomst niet: over $\varepsilon = 0.01$ tot 0.12 blijft de cosinus met de schatter tussen 0.69 en 0.72.

Wat de correctie waard is — nog niets, zonder de rest bij te stellen

De ontbrekende factor toevoegen is één regel code. Wij hebben het gedaan, op het volledige brein, met g als versterking van het wolkeel van het spoor — en het resultaat is de moeite waard om te melden juist omdat het tegenvalt:

versterking g	succes laatste 20	toets	actieve verbindingen
1 (huidige leerregel)	90.0% $\pm$ 8.1	67.5% $\pm$ 5.6	1441
10	48.1% $\pm$ 4.5	21.3% $\pm$ 6.9	308
30	34.4% $\pm$ 5.4	9.4% $\pm$ 3.4	324
100	40.0% $\pm$ 1.9	5.6% $\pm$ 3.4	520
272	36.9% $\pm$ 4.5	1.9% $\pm$ 2.6	1198

8 zaden per waarde, 500 pogingen, leersnelheid ongewijzigd. Het leren stort in. Dat is geen weerlegging van de meting maar een bevestiging van wat zij zegt: als het wolkeel twee ordes groter wordt terwijl η en de stapbegrenzing op de oude schaal blijven staan, loopt elke update in de wolk tegen de begrenzing uit sectie 3.7 aan en verliest die haar functie. De huidige η is stilzwijgend op de ónjuiste schaal afgesteld.

De schone tegenproef schaalt de leersnelheid mee met $1/g$. Dan blijft het wolkeel op zijn oude grootte en wordt het knopdeel g keer zachter — dezelfde verschuiving in de onderlinge verhouding, zonder dat de totale stap ontloft:

versterking g	succes laatste 20	toets	actieve verbindingen
1 (huidige leerregel)	90.0% ± 8.1	67.5% ± 5.6	1441
10	52.5% ± 8.7	37.5% ± 6.4	1475
30	15.0% ± 11.9	14.4% ± 8.2	1478
100	3.8% ± 6.1	4.4% ± 5.1	1487
272	0.0% ± 0.0	2.5% ± 3.7	1509

Ook zo wint geen enkele waarde van g het van de bestaande verhouding. De conclusie is dan dat de scheve schaal wel aantoonbaar is op de miniatuurgraaf, maar dat het herstellen ervan met alleen deze ene knop niet werkt: leersnelheid, stapbegrenzing en exploratie hangen samen en moeten als geheel opnieuw afgesteld worden. Dat is een ablatie op zichzelf en hoort niet in deze sectie thuis.

Wat er wél staat is dit: de leerregel bevat een aantoonbare schaalfout, die op de miniatuurgraaf de cosinus met de echte gradiënt van 0,12 naar 0,83 scheelt, en die in het volledige model niet met één parameter recht te zetten is. Dat is een scherpere en eerlijkere uitspraak dan de oorspronkelijke "de schatter is zuiver op een tweede-ordeterm na".

3.12 Vier varianten van de leerregel

De regel hierboven is de regel die in de rest van dit document "ANG" heet. Er zijn vier plekken waar zij op een standaardmanier scherper gemaakt kan worden zonder haar lokale karakter op te geven, en alle vier zijn ze als losse schakelaar in de implementatie aanwezig zodat ze meetbaar zijn in plaats van aangenomen. Ze worden hier gedefinieerd; wat ze opleveren staat in sectie 10.6.

- **Een toestandsafhankelijke criticus.** De basislijn b in vergelijking 12 is één lopend gemiddelde over spelstappen en dus toestandsloos. In de variant komt daar een lineaire schatter $V(s) = w \cdot s + b$ voor in de plaats, op dezelfde zestien sensoren, bijgewerkt met $TD(0) \leftarrow w \leftarrow w + \eta_V \cdot \delta \cdot s$ met $\delta = r + \gamma V(s') - V(s)$ — en wordt δ de $\hat{A}$ uit vergelijking 12. De schatter is een tweede, losse leerder naast de graaf; door het netwerk wordt niets teruggepropageerd, dus de update van een synaps blijft opgebouwd uit grootheden die op die synaps beschikbaar zijn. In de metingen: $\eta_V = 0,02$, $\gamma = 0,95$.
- **Schaarse perturbatie.** De ruis ξ wordt per tik aan een willekeurige deelverzameling van de wolk toegevoegd in plaats van aan alle knopen. De variantie van een perturbatieschatter groeit met het aantal knopen dat tegelijk beweegt; niet-verstoorde knopen krijgen die tik afwijking nul en dus geen spoor.
- **Een categorisch beleid.** In plaats van vier onafhankelijke Bernoulli-knopen één softmax over negen elkaar uitsluitende acties: de acht richtingen en stilstaan. De score van een actie is de som van de netto-ingangen van de knopen die zij indrukt, gedeeld door τ , zodat het aantal uitvoerknopen vier blijft en de score-functie haar vorm behoudt: $\partial \log \pi / \partial \text{net}_k = (1[k \text{ ingedrukt}] - P(k))$, met $P(k)$ de randkans van knop k onder de categorische verdeling. Bij onafhankelijke knopen is $P(k)$ de sigmoïde zelf en staat er weer vergelijking 11.
- **De ontbrekende normalisatie g.** Het wolkdeel van het spoor met een factor g vermenigvuldigen, als benadering van de $1/\text{Var}(\xi)$ die de standaardformulering van node-perturbatie heeft en die volgens sectie 3.11 in ANG ontbreekt. Anders dan in 3.11 wordt g hier gemeten met een leersnelheid die op g is afgesteld.

4 Structurele plasticiteit

Tot hier verandert alleen de sterkte van bestaande verbindingen. De tweede helft van het model verandert de graaf zelf. Dat gebeurt niet elke stap maar in rondes, eens per K pogingen, zodat de structuur rustiger verandert dan de gewichten.

4.1 Snoeien

Elke verbinding houdt bij hoe lang zij al zwak is. Eén ronde zwak zijn is niet genoeg; pas wie twee ronden achtereen onder de drempel blijft, verdwijnt:

$$n_{ij} \leftarrow (n_{ij} + 1) \cdot \mathbf{1}[|w_{ij}| < \theta_p], \quad \text{snoei indien } n_{ij} \geq 2 \quad (24)$$

Een zelfverbinding van een geheugen-neuron wordt nooit gesnoeid (invariant I4), en een verbinding die de laatste uitweg van een invoerknoop of de laatste toevoer van een uitvoerknoop is evenmin (I1, I2).

4.2 Aangroei van verbindingen

In dezelfde ronde komen er nieuwe verbindingen bij, met een klein willekeurig gewicht. De bron wordt gekozen met een lichte voorkeur voor magere neuronen: uit drie willekeurige kandidaten wordt die met de laagste graad genomen. Zo groeit de bedrading eerder aan waar weinig zit dan waar al veel zit, zonder dat er een harde regel over graden nodig is. Elke voorgestelde boog wordt getoetst aan L en genegeerd als hij niet mag.

4.3 Groei van neuronen

Als het leren vastloopt, mag er materiaal bij. Stagnatie wordt gemeten door de gemiddelde opbrengst van het laatste blok pogingen te vergelijken met dat daarvóór:

$$\text{stagnatie} \Leftrightarrow \frac{1}{k} \sum_{e=E_0-k}^{E_0-1} R_e \leq 1.02 \cdot \frac{1}{k} \sum_{e=E_0-2k}^{E_0-k-1} R_e + 0.05 \quad (25)$$

Is aan die voorwaarde voldaan en is het plafond op het aantal neuronen nog niet bereikt, dan komen er nieuwe neuronen bij. Zij komen neutraal binnen: zij horen nog bij geen enkele soort en mogen daardoor alles. Twee details bepalen of zij ooit meedoen. Ten eerste worden zij geboren met ongeveer dezelfde graad als de rest van de wolk, niet met een handvol verbindingen: in een netwerk met duizenden verbindingen valt een neuron met vier bogen volledig weg in de ruis. Ten tweede krijgen hun verbindingen een respijt van twee opruimrondes, zodat zij niet gesnoeid worden voordat zij zich hebben kunnen bewijzen. Daarbovenop krijgt elk nieuw neuron gegarandeerd één boog vanaf een invoerknoop en één naar een uitvoerknoop, zodat het vanaf het begin in een pad ligt en dus leersignaal ontvangt.

Dat dit ertoe doet is geen theorie. Met een klein vast aantal startverbindingen bleef in onze metingen bijna de helft van de neuronen na afloop losgekoppeld — het waren vrijwel allemaal bijgegroeide neuronen die nooit geïntegreerd raakten. Met graadgelijke geboorte en het respijt daalde dat aandeel naar enkele procenten, zonder dat de prestatie veranderde. De maat *deelnemende neuronen* uit sectie 6 was precies het instrument dat dit zichtbaar maakte.

4.4 Soorttoewijzing: de meest specifieke soort die past

De vraag welke soort een neuron moet krijgen, beantwoorden wij niet met een aparte heuristiek per soort maar met één criterium: **welke soort is dit neuron, gemeten aan de bedrading die het al heeft?** De kosten van een soort zijn de gewichtsmassa die verloren zou gaan omdat de regels van die soort haar verbieden:

$$C(i, t) = \sum_{(a,b) \in E_i} \mathbf{1}[\neg L_t(a, b)](|w_{ab}| + 0.02) + 0.05 \cdot \mathbf{1}[t \neq \text{work}] \quad (26)$$

waarin E_i de verbindingen zijn waarbij neuron i betrokken is en L_t de toelaatbaarheidsrelatie zoals die zou gelden als i soort t had. De kleine constante per verboden boog voorkomt dat het schrappen van louter nulverbindingen gratis is.

Op kosten alleen kan echter niet gekozen worden, en dat is een les die ons een halve dag heeft gekost. **Blijven kost per definitie niets** — alle bestaande verbindingen zijn immers toelaatbaar — en omschakelen naar worker kost ook niets, want die soort verbiedt niets. Een criterium dat de goedkoopste soort kiest, verandert dus vroeg of laat élk neuron in een worker, en de gespecialiseerde soorten verdwijnen stilletjes uit het netwerk. In onze metingen gebeurde precies dat: van negen reflex-neuronen waren er na vierhonderd pogingen nog drie over, en van de werkende reflexbogen bleef er geen enkele staan.

Wat ontbreekt is een tegenkracht: hoe strenger de regels van een soort, hoe meer het zegt dat een neuron er toch aan voldoet. Wij geven elke soort daarom een *specificiteitsbonus* — reflex het hoogst, dan invoer-neuron, dan geheugen, en worker nul — en kiezen de laagste som:

$$T(i) = \operatorname{argmin}_{t \in A(i)} C(i, t) \quad (27)$$

over de toegestane verzameling $A(i)$, die de quota van de gebruiker en de meerderheidsregel afdwingt:

$$n_{\text{work}} > n_{\text{sens}} + n_{\text{refl}} + n_{\text{mem}}, \quad m_i \leq n_i \leq M_i \quad (28)$$

Een neutraal neuron neemt altijd de beste toegestane soort — het heeft niets te verliezen. Een neuron dat al een soort heeft, wisselt alleen als de nieuwe soort duidelijk beter scoort dan blijven, met een marge μ die heen-en-weergeschuif voorkomt, én als de kosten onder de door de gebruiker gestelde drempel blijven:

$$T(i) \neq \kappa(i) \Leftrightarrow C(i, T(i)) - C(i, \kappa(i)) < -\mathcal{S}(\kappa(i)) - \mu \text{ en } C(i, T(i)) \leq C_{\max}, \quad \mu = 0.02 \quad (36)$$

Wat er daarna aan verboden verbindingen overblijft, wordt verwijderd, en een neuron dat geheugen wordt, krijgt zijn zelfverbinding. Het aardige van deze formulering is dat de bekende gevallen er als bijzondere gevallen uit rollen. Een neuron dat alleen invoerknoppen als bron heeft, kost niets als invoer-neuron en wint dus van worker. Een neuron dat uitsluitend tussen invoer-neuronen en knoppen hangt, is per definitie een reflex en krijgt de hoogste bonus. Een neuron in een lus kost als reflex zijn hele terugkoppeling en blijft dus worker of wordt geheugen. Er is geen aparte regel per soort nodig — alleen een rangorde van strengheid.

4.5 Recycling

Een neuron dat na het snoeien geen enkele verbinding meer overhoudt, verliest zijn soort en wordt weer neutraal. Het is daarmee vrij materiaal: bij de volgende ronde kan het opnieuw bedraad worden en een andere soort krijgen. Zo verdwijnt niets uit het netwerk, maar wordt wel hergebruikt wat niet meer meedoet.

4.6 Herstel van de invarianten

Aan het einde van elke ronde worden de invarianten hersteld: elke invoerknoop zonder uitweg krijgt er een, elke uitvoerknoop zonder toevoer krijgt er een, elk geheugen-neuron zonder zelfverbinding krijgt haar terug. Pas daarna wordt de graaf weer vastgelegd in de compacte datastructuren van sectie 7.

Algoritme 2 — herstructureren

```

herstructureer(brein B, instellingen c):
  1 snoei zwakke verbindingen (24)
  2 neuronen zonder verbindingen → neutraal
  3 voor elk neutraal neuron: T(i) ← argmin C(i,t) (26, 27)
    voor enkele bestaande neuronen: idem, mits C ≤ Cmax
    verwijder de verbindingen die daardoor verboden zijn
  4 als stagnatie en n < nmax: voeg neutrale neuronen toe (25)
  5 laat nieuwe verbindingen aangroeien (voorkeur: lage graad)
  6 herstel I1, I2, I4

```

5 Omgeving, waarneming en beloning

Een leerregel is niet los te beschrijven van wat er te leren valt. De instantie waarin ANG hier draait is een continue tweedimensionale wereld waarin een karakter een doel moet bereiken zonder tegen obstakels te botsen. Start en doel liggen tegen twee tegenoverliggende randen, en welke randen dat zijn wisselt per wereld, zodat een vaste voorkeursrichting geen oplossing is. De obstakels liggen in het middengebied. Elke gegenereerde wereld wordt met een breedtezoektocht op oplosbaarheid getoetst voordat hij gebruikt wordt.

5.1 Waarneming

Het netwerk krijgt zestien getallen, en verder niets — geen coördinaten, geen kaart, geen geheugen van eerdere pogingen. Acht ervan meten in acht windrichtingen de nabijheid van het dichtstbijzijnde obstakel of de wereldrand:

$$s_d = 1 - \frac{\min(\rho_d, \rho_{\max})}{\rho_{\max}}, \quad d = 1, \dots, 8 \quad (29)$$

waarin ρ_d de afstand langs straal d is. De andere acht coderen het doel als een richting-met-nabijheid: hoe beter een richting naar het doel wijst en hoe dichterbij het doel is, hoe hoger de waarde.

$$g_d = \max(0, \langle \mathbf{u}_d, \hat{\mathbf{g}} \rangle) \left(1 - \frac{\min(D, D_{\max})}{D_{\max}}\right) \quad (30)$$

Beide families zijn zo geschaald dat nul "niets aan de hand" betekent. Dat is geen detail: bij een nulwaarde levert een verbinding geen bijdrage aan de netto-invoer en ook geen spoor, zodat een neuron dat op een stille sensor is aangesloten vanzelf onbelast blijft.

5.2 Beloning

De beloning per stap is een som van vijf termen:

$$r_t = c_p(D_{t-1} - D_t) - c_s - c_i \mathbf{1}[\text{stil}] - c_c \mathbf{1}[\text{botsing}] + c_g \left(1 + \frac{1}{2} \left(1 - \frac{1}{T}\right)\right) \mathbf{1}[\text{doel}] \quad (31)$$

De eerste term beloont dichterbij het doel komen, de tweede is een kleine tijdskost, de derde bestraft stilstand, de vierde een botsing, en de vijfde is de eindbeloning met een bonus naarmate het doel sneller bereikt wordt.

5.3 De dichtheidsterm is potentiaal-gebaseerd

De term die vooruitgang beloont, verdient een opmerking. Het is verleidelijk te denken dat zo'n term het probleem verandert — dat het netwerk leert "dichterbij komen" in plaats van "het doel bereiken". Dat is hier niet zo. Met de potentiaal $\Phi(s) = -c_p D(s)$, waarin D de afstand tot het doel is, geldt namelijk

$$\Phi(s) = -c_p D(s) \quad \Rightarrow \quad c_p(D_{t-1} - D_t) = \gamma \Phi(s_t) - \Phi(s_{t-1}), \quad \gamma = 1 \quad (32)$$

en dat is precies de vorm waarvan Ng, Harada en Russell [9] hebben aangetoond dat zij het optimale beleid ongemoeid laat. De term versnelt het leren zonder de opgave te veranderen. Zet men hem op nul, dan blijft dezelfde opgave over, maar met beloning die pas aan het eind komt — een goede manier om te laten zien hoe moeizaam leren wordt bij ijl beloningssignaal.

5.4 Hoe je een stochastisch beleid toetst

Bij het toetsen op onbekende werelden ligt een fout op de loer. Het beleid *is* stochastisch: elke knop is een kans en de actie wordt geloot. Het is verleidelijk om bij een toets de loting weg te laten en steeds de waarschijnlijkste knop te nemen, want dat lijkt "het geleerde beleid zonder ruis". Dat is het niet — het is een ander, en meetbaar slechter beleid. Een agent die deterministisch twee knoppen tegelijk ingedrukt houdt tegen een muur, blijft daar oneindig staan; dezelfde kansen laten hem binnen een paar stappen loskomen.

De toets draait daarom met dezelfde loting als tijdens het leren, maar zonder leren, zonder ruis in de wolk en met een eigen toevalsgenerator, zodat de toets reproduceerbaar is en de training niet verstoort. De strengere variant wordt niet als alternatief gebruikt maar in elke run ernaast gemeten, want het verschil tussen beide is zelf een grootheid: het zegt hoeveel van de prestatie op de scherpte van de beslissingen berust en hoeveel op het blijven bewegen.

En dat verschil is groot. Over 16 breinzaden haalt het geleerde, gelote beleid op de benchmarkset van sectie 10.2 $65.4\% \pm 2.0$, terwijl steeds de waarschijnlijkste knop nemen op diezelfde werelden blijft steken op $52.3\% \pm 3.0$. Gepaard per zaad scheelt dat -13.1 ± 2.3 procentpunt in het nadeel van argmax (Mann-Whitney U, $p < 0,001$). Het toeval is dus geen ruis die je er bij het toetsen netjes uit haalt — het is onderdeel van de strategie geworden. Wie deze twee door elkaar haalt, meet een ander beleid dan hij getraind heeft, en onderschat het resultaat met ruwweg een achtste van de score.

6 Het meten van de gevormde structuur

Wat een ANG uiteindelijk gebouwd heeft, is de eigenlijke uitkomst. De volgende maten worden op de actieve deelgraaf berekend, dat wil zeggen op de verbindingen die zwaar genoeg zijn om ertoe te doen:

$$E_\theta = \{(a, b) \in E : |w_{ab}| > 0.08 w_{\max}\} \quad (33)$$

De drempel is bewust *relatief* aan het zwaarste gewicht dat er werkelijk is, en niet aan het plafond $w_{\max}$. Gewichten blijven in de praktijk ruim onder dat plafond; een absolute drempel verklaart daardoor bijna elke verbinding voor inactief en laat een werkend brein structuurloos lijken. Bij de waarden uit sectie 8 scheelt dat een orde van grootte in het aantal verbindingen dat meetelt.

Kortste pad van zintuig naar knop

De lengte in bogen van het kortste pad in E_θ van een willekeurige invoerknoop naar een willekeurige uitvoerknoop. Twee is het minimum dat de regels toelaten. Bestaat er geen pad, dan is het brein per definitie stuurloos — een diagnose die je aan de prestatie alleen niet zou zien.

Lussen

Het aantal sterk samenhangende componenten van meer dan één knoop in de actieve deelgraaf, plus het aantal actieve zelfverbindingen van geheugen-neuronen. Dit telt hoeveel echte terugkoppeling er in het netwerk zit.

Werkende reflexbogen

Het aantal reflex-neuronen dat zowel vanaf de invoer bereikbaar is als een actieve uitgang heeft. Dit is de maat voor "heeft dit brein een korte weg van zintuig naar spier gevormd".

Deelnemende neuron

Een neuron doet mee als het bereikbaar is vanaf de invoer én de uitvoer kan bereiken. De rest is losgeraakt: het draait wel mee in de berekening, maar kan het gedrag onmogelijk beïnvloeden. Het verschil tussen "aantal neuron" en "aantal meedoende neuron" is de eerlijkste maat voor hoe groot een netwerk werkelijk is.

Sensorinvloed

Voor elke invoerknoop sommeren wij de gewichtsmassa die haar via paden van hoogstens vijf bogen bereikt aan de uitvoer:

$$\nu_i = \sum_{h=1}^5 \sum_{o \in \mathcal{O}} (\widetilde{W}^h)_{io}, \quad \widetilde{W}_{ab} = \min\left(1, \frac{|w_{ab}|}{w_{\max}}\right) \quad (34)$$

Dit is een afgeknotte padsom, verwant aan Katz-centraliteit. Zij maakt zichtbaar welke zintuigen het netwerk feitelijk gebruikt en welke het volledig negeert — informatie die uit de prestatie alleen nooit af te lezen is.

7 Implementatie

Het model, de meetscripts en dit document zijn tot stand gekomen met behulp van een generatief AI-hulpmiddel (Claude, Opus 5, Anthropic). Wat dat hulpmiddel precies heeft gedaan, en waarom het niet als auteur is opgevoerd, staat in de verklaring achter in dit document. Het wordt hier genoemd omdat het bij de werkwijze hoort en niet bij de kleine lettertjes.

7.1 Indexering en datastructuren

De knopen liggen in een vaste volgorde: eerst de zestien invoerknopen, dan de vier uitvoerknopen, dan de wolk. Die volgorde is met opzet gekozen. Zij zorgt dat een neuron dat er tijdens het trainen bij komt achteraan wordt toegevoegd, zodat geen enkel bestaand nummer verschuift en geen enkele opgeslagen verbinding hoeft te worden omgenummerd. De verbindingen zelf staan in vier parallelle getypeerde arrays — bron, doel, gewicht, spoor — wat de propagatie een enkele lus over aaneengesloten geheugen maakt.

7.2 Complexiteit

Per spelstap en per poging:

$$C_{\text{tik}} = \mathcal{O}(P(|E| + |V|)), \quad C_{\text{poging}} = \mathcal{O}(TP(|E| + |V|)) \quad (35)$$

De dominante term is het aantal verbindingen, niet het aantal neuronen: een wolk van zestig neuronen met tweeduizend verbindingen rekent trager dan een wolk van tweehonderd neuronen met vijfhonderd. Het herstructureren is lineair in het aantal verbindingen op de soorttoewijzing na, die per kandidaat-neuron één keer over de verbindingen loopt. De krachtenmodel-lay-out voor de weergave is kwadratisch in het aantal knopen en wordt daarom alleen bij structuurveranderingen opnieuw uitgevoerd.

7.3 Numerieke waarborgen

Alle activaties liggen door tanh en σ binnen begrensde intervallen; alle gewichten en biassen zijn hard begrensd op $\pm w_{\max}$; de advantage is begrensd; de sporen zijn genormaliseerd. Er is geen plek in het model waar een grootheid ongelimiteerd kan groeien, wat verklaart waarom er ook bij duizenden pogingen geen numerieke ontsporing optreedt.

7.4 Reproduceerbaarheid

Een run wordt volledig vastgelegd door twee zaadwaarden. Het **breinzaad** bepaalt de startwolk: welke neuronen welke soort krijgen, waar de eerste verbindingen liggen en met welke gewichten zij beginnen. Het **wereldzaad** bepaalt de reeks werelden en, via een tweede deterministische generator, alle ruis tijdens het leren — de perturbaties in de wolk, de loting van de vier knoppen en elke keuze in de herstructurering. De toets op onbekende werelden heeft een eigen, vaste generator, zodat toetsen

de training niet verstoort en zelf herhaalbaar is. Nergens in het leertraject wordt de generator van de omgeving aangeroepen.

Dat is geen ontwerpvens maar een gecontroleerde eigenschap. Dezelfde twee zaden worden twee keer achter elkaar gedraaid, waarna de volledige leercurve, alle tussentijdse toetsen, alle structuurmaten en het volledige eindnetwerk — knoop voor knoop en verbinding voor verbinding — bit voor bit worden vergeleken. Bij 3 zaadwaarden, elk over 200 pogingen, was de uitkomst in alle gevallen identiek.

Elke afgeronde training wordt weggeschreven met alle instellingen, beide zaden, de geschiedenis per poging, de toetsen op onbekende werelden, het logboek van herstructureringen en de volledige eindstructuur van het netwerk — alle knopen met hun soort, hun positie en hun bias, en alle verbindingen met hun gewicht. Bijlage B geeft de volledige veldenlijst. Zo'n bestand is niet alleen leesbaar maar ook laadbaar: het netwerk kan er ongewijzigd uit teruggebouwd worden om opnieuw getoetst te worden, om verder te trainen, of om als startpunt voor een variant te dienen. Dat maakt de meetopstelling ook geschikt voor reeksen: een lijst condities maal zaden wordt achter elkaar afgedraaid en levert per run een bestand en één regel in een gezamenlijke tabel.

8 Parameters

Onderstaande tabel vat de vrije parameters samen, met de waarden die als standaard gelden. De laatste kolom geeft aan waar de parameter in het model optreedt.

Symbool	Betekenis	Standaard	Zie
n	aantal neuronen bij de start	60	sectie 2.1
d	startdichtheid: uitgaande verbindingen per neuron	35	sectie 4.2
P	propagatiestappen per spelstap	1	vgl. 4–6
α	geheugenlek	0,15	vgl. 6
η_0	leersnelheid	0,008	vgl. 17
λ	sporenvervaging	0,60	vgl. 14
β	aanpassingssnelheid van de basislijn	0,02	vgl. 15
$w_{\max}$	maximaal gewicht	2,0	vgl. 18, 20
$\Delta_{\max}$	maximale verandering per stap	0,100	vgl. 19
ρ	vervaging per poging	0,0001	vgl. 21
ε_0	exploratie bij aanvang	0,30	vgl. 22
ε_∞	ondergrens exploratie	$\max(0,3 \varepsilon_0 ; 0,03)$	vgl. 22
K	pogingen tussen twee herstructureringen	10	sectie 4
θ_p	snoidrempel	0,030	vgl. 24
—	nieuwe verbindingen per ronde	6	sectie 4.2
$n_{\max}$	plafond op het aantal neuronen	140	sectie 4.3
—	nieuwe neuronen per ronde	2	sectie 4.3
$C_{\max}$	maximale omschakelkosten	0,25	vgl. 27
—	obstakels in de wereld	7	sectie 5
T	stappen per poging	320	sectie 5
E	aantal pogingen	500	algoritme 1
—	werelden per tussentijdse toets	20	sectie 5.4

Symbool	Betekenis	Standaard	Zie
—	werelden in de benchmarkset $\times$ keer gespeeld	500×3	sectie 10.2

9 Beperkingen

- **De gradiëntschatter is ruis.** Node-perturbatie levert een zuivere maar variabele schatting; de variantie groeit met het aantal knopen dat tegelijk verstoord wordt. Dat begrenst hoe groot een wolk zinvol kan worden zonder de leersnelheid te verlagen.
- **De twee delen van de update staan niet op dezelfde schaal.** Sectie 3.11 meet dat het node-perturbatiedeel twee ordes te klein is ten opzichte van het score-functiedeel, doordat de normalisatie $1/\text{Var}(\xi)$ ontbreekt. Met één leersnelheid krijgt de wolk daardoor nauwelijks een update. Dit is de scherpste bekende tekortkoming van de leerregel; het herstellen ervan vraagt om de leersnelheid en de stapbegrenzing samen opnieuw af te stellen, en dat is nog niet gedaan.
- **De uitkomst hangt af van het punt in de gewichtsruimte.** De cosinus van het wolkdeel met de echte gradiënt loopt in dezelfde opstelling van 0,27 bij een vers brein tot 0,83 na tweehonderd pogingen leren. Eén meting op één punt zegt dus weinig; de controle is uitgevoerd op drie punten en zelfs dat is weinig.
- **De controle is klein.** De numerieke gradiënt is alleen na te rekenen op een graaf met vier verborgen knopen en een bevroren topologie, in een omgeving waarin die miniatuuragent het doel zelden haalt. Dat J daar vooral door de dichtheidsterm wordt bepaald is geen bezwaar voor het toetsen van de leerregel — dat is ook het signaal dat het brein tijdens de training grotendeels ziet — maar het blijft een ander regime dan het volledige model.
- **Geen kritiek-functie.** De advantage is een lopend gemiddelde over stappen, geen toestandsafhankelijke waardeschatting. In toestanden die systematisch beter of slechter zijn dan gemiddeld, is het signaal daardoor vertekend.
- **Soorttoewijzing is lokaal.** Het criterium in vergelijking 26 kijkt alleen naar de bogen van het neuron zelf, niet naar wat de verandering verderop in het netwerk aanricht. Ook de rangorde van specificiteit is een ontwerpkeuze en geen afgeleid resultaat; een criterium dat de doorstroming over paden meeweegt zou principiëler zijn.
- **Groei kent geen krimp.** Neuronen kunnen bijkomen en hun soort verliezen, maar worden nooit verwijderd. Een netwerk dat te ver doorgroeit kan alleen nog verdunnen, niet inkrimpen.
- **De structuurmaten hangen aan een drempel.** Wat "actief" heet, is een keuze: een andere drempel geeft andere padlengtes, andere lussen en andere reflexbogen. De maten zijn geschikt om breinen met elkaar te vergelijken, niet als absolute grootheid.
- **Eén omgeving.** Alle ontwerpbeslissingen zijn gemaakt met één taak voor ogen. Welke ervan algemeen zijn en welke aan die taak vastzitten, is een open vraag.
- **De benchmarkset is één trekking uit één generator.** Vijfhonderd werelden halen de meetruis omlaag, maar zij komen alle uit dezelfde wereldgenerator met hetzelfde aantal obstakels. Het interval eromheen zegt hoe zeker de score op deze verdeling is, niet hoe het model het doet op werelden die anders in elkaar zitten. Sectie 10.4 noemt de tweede taak die dat moet uitwijzen.
- **Alle instellingen zijn op de trainingsverdeling gekozen.** De standaardwaarden uit sectie 8 zijn afgesteld vóórdat de benchmarkset bestond, op twintig toetswerelden. De benchmark is sindsdien nooit gebruikt om iets te kiezen, maar de instellingen die zij beoordeelt zijn wel met een minder betrouwbaar signaal tot stand gekomen. Het raster van dichtheid tegen aantal neuronen wordt daarom opnieuw gedraaid met de benchmark als toets.
- **De ablatiereeks draait op één leersnelheid.** Elke conditie in sectie 10.7 gebruikt $\eta = 0,008$, de waarde die voor het volle model is afgesteld. Het argument daarvoor is dat een ablatie de graaf

verandert en niet de schaal van het leersignaal, zodat meesturen van η zou meten hoe goed een conditie opnieuw af te stellen is. Dat argument is redelijk maar niet gemeten: een conditie die het slechter doet zou in beginsel een andere η kunnen willen, en de reeks kan dat niet uitsluiten.

10 Evaluatie

De meetopzet is met opzet niet ingericht om te laten zien dat het model werkt, maar om uit elkaar te trekken wáár een eventuele prestatie vandaan komt. Deze versie van het document bevat de benchmarkset, de referentiemeting daarop en de reproduceerbaarheidscontrole, en sectie 3.11 de numerieke controle van de leerregel zelf; sectie 10.4 tot en met 10.7 bevatten de basislijnen, de rekenkostentabel, de varianten van de leerregel en de ablatiereeks. Sectie 10.8 varieert vervolgens de waarneembaarheid van de omgeving, sectie 10.9 laat de omgeving binnen één leven omslaan, en sectie 10.10 stelt vier vragen aan al dat materiaal samen zonder nieuwe metingen te doen.

10.1 Twee meetassen

Prestatie wordt gescheiden gemeten op de werelden waarin getraind is en op werelden die het netwerk nooit gezien heeft. Het verschil tussen die twee is de eigenlijke grootte: het onderscheidt het uit het hoofd leren van een route van het leren navigeren. Daarnaast wordt na elke run de gevormde structuur met de maten uit sectie 6 vastgelegd, zodat de vraag beantwoord kan worden welke structurele eigenschappen met goed presteren samenhangen.

Over onzekerheid. Er zijn er twee, en ze worden makkelijk verward. De eerste is de spreiding *tussen zaden*: hetzelfde recept levert verschillende breinen op. De tweede is de onzekerheid *binnen één run*: op hoeveel werelden is die ene agent afgerekend? Beide staan hieronder als 95%-interval, en ze horen niet bij elkaar opgeteld te worden. Overlappen twee intervallen elkaar ruim, dan is een verschil niet aangetoond, hoe suggestief het gemiddelde ook oogt.

10.2 Waarop getoetst wordt: een vaste benchmarkset

Tijdens het leren loopt elke twintig pogingen een toets mee op twintig onbekende werelden. Dat is een bruikbaar en goedkoop signaal, maar het draagt geen conclusie: bij een score rond 70% is het 95%-interval van twintig trekkingen ongeveer ± 20 procentpunt. Twee condities die in werkelijkheid tien procentpunt schelen, zijn zo niet uit elkaar te houden.

Wat in dit document staat, komt daarom van een vaste benchmarkset: 500 werelden uit een eigen zaadreeks, met vast 7 obstakels, gescheiden van de trainingswerelden én van de twintig werelden die tijdens het leren meelopen. Zij wordt nooit gebruikt om instellingen te kiezen. Omdat het beleid geloot wordt, speelt elke wereld 3 keer; het interval gaat over de werelden en niet over de speelbeurten, want drie keer dezelfde wereld spelen levert geen drie onafhankelijke waarnemingen over generalisatie op. Daarmee zakt de onzekerheid van één meting naar ± 3.6 procentpunt. De verzameling ligt vast in experimenten/benchmark-werelden.json, met een controlegetal waarmee een afwijking direct opvalt.

Twee ijkpunten op diezelfde werelden

Een schaal zonder ijkpunt meet niets. Een agent die elke tik een willekeurige richting kiest haalt op deze werelden **0.0%** — de vloer. Een zuiver reactieve agent met precies dezelfde zintuigen als het netwerk, die naar het doel toe wordt getrokken en van wat vlakbij staat wordt afgestoten, haalt **38.6% ± 4.3** . Dat is wat zonder geheugen, zonder planning en zonder leren haalbaar is, en het is de ondergrens waar alles wat het netwerk leert bovenuit moet komen.

Hoeveel dat scheelt, laat de ijkagent zelf zien. Dezelfde agent, hetzelfde soort werelden: op twintig toetswerelden scoort hij $30.0\% \pm 20.6$, op de vijfhonderd benchmarkwerelden $38.6\% \pm 4.3$. Een verschil van 9 procentpunt zonder dat er iets aan het beleid veranderd is — geheel binnen wat twintig

trekkingen aan speling geven. Dat is de omvang van de fout die men maakt door een generalisatiecijfer op twintig werelden te baseren.

10.3 Referentiemeting

De standaardconfiguratie — 60 neuronen bij aanvang, startdichtheid 35, 7 obstakels, 320 stappen per poging, 500 pogingen — is over 16 onafhankelijke breinzaden gedraaid, alle met hetzelfde wereldzaad, zodat de zaden alleen in de startwolk verschillen. Dit is de conditie waartegen elke latere ablatie wordt afgezet.

grootheid	gemiddelde $\pm$ 95%	spreiding (sd)	bereik
succes over alle pogingen	63.0% $\pm$ 1.7	3.5%	57–70%
succes laatste 20 pogingen	87.2% $\pm$ 4.6	9.5%	70–100%
toets, 20 werelden (goedkoop signaal)	68.1% $\pm$ 3.6	7.3%	55–80%
benchmark, geleerd beleid	65.4% $\pm$ 2.0	4.1%	58–72%
benchmark, altijd de beste knop	52.3% $\pm$ 3.0	6.1%	44–64%
stappen bij een geslaagde poging	161 $\pm$ 4	9	145–180
rekentijd per run (s)	7.0 $\pm$ 0.2	0.3	6–7

Het verschil tussen de laatste twintig trainingspogingen (**87.2% $\pm$ 4.6**) en de benchmarkset (**65.4% $\pm$ 2.0**) is 21.8 procentpunt. Dat gat is de kern van de vraag waaruit dit werk voortkomt. Het is klein genoeg om te concluderen dat er navigatiegedrag geleerd is en niet louter een route onthouden, en groot genoeg om te laten zien dat het onthouden meespeelt. De sd van 9.5% op de trainingsscore is bovendien het getal dat bepaalt hoeveel zaden een latere vergelijking nodig heeft: met deze spreiding is een verschil van tien procentpunt pas boven de ruis bij ruwweg zestien runs per conditie.

Ten opzichte van de ijkpunten. Het netwerk haalt op de benchmark 65.4%, de reactieve agent 38.6% en een willekeurig beleid 0.0%. De marge op de reactieve ondergrens is 27 procentpunt, ruim buiten beide intervallen. Wat het netwerk leert, is dus meer dan "naar het doel toe en van muren weg" — maar daarmee is nog niets gezegd over de vraag of de graafstructuur daaraan bijdraagt of alleen de leerregel; dat is wat de ablaties en de gelaagde basislijn moeten uitwijzen.

Twee onzekerheden, uit elkaar gehouden. Het interval van $\pm$ 2.0 procentpunt hierboven gaat over de zaden: het zegt hoe goed dit récept is. Binnen één run is de onzekerheid over de werelden $\pm$ 3.6 procentpunt: dat zegt hoe goed dít brein is. De eerste is de grootheid waarmee condities vergeleken worden; de tweede is de reden dat er vijfhonderd werelden nodig waren.

De structuur die eruit komt

Dezelfde runs, nu afgelezen met de maten uit sectie 6. Deze tabel is niet illustratief maar de nulmeting waartegen sectie 6 in een volgende versie op prestatie gecorreleerd wordt.

structuurmaat	gemiddelde $\pm$ 95%	bereik
neuronen aan het eind	111 $\pm$ 2	106–116
meedoende neuronen	105 $\pm$ 4	88–115
verbindingen	2996 $\pm$ 35	2905–3157
actieve verbindingen	1446 $\pm$ 90	1132–1711
kortste pad zintuig $\rightarrow$ knop	2.00 $\pm$ 0.00	2–2
terugkoppellussen	11.0 $\pm$ 0.0	11–11
werkende reflexbogen	3.7 $\pm$ 1.3	0–8

Twee dingen vallen op. Het kortste pad is bij vrijwel elke run 2: het netwerk bouwt een directe verbinding van zintuig naar knop en houdt die, ondanks dat er niets in de leerregel is dat korte paden beloont. En het aantal reflexbogen loopt van 0 tot 8 — een spreiding die groter is dan het gemiddelde. Reflexbogen ontstaan dus wel, maar niet betrouwbaar; of ze iets bijdragen is precies wat de ablatie zonder reflex-neuronen moet uitwijzen.

10.4 Basislijnen binnen dezelfde leerregel

De referentiemeting zegt dat het netwerk leert, niet waaraan dat ligt. De leerregel van sectie 3 vraagt nergens om een graaf: zij werkt op elke topologie waarop de knoop-update van vergelijking 4 gedefinieerd is. Het is dus goed mogelijk dat de leerregel al het werk doet en de structuur er niets aan toevoegt. Om dat uit elkaar te trekken zijn vier condities gedraaid die alles delen behalve de bedrading: dezelfde knoop-update, dezelfde node-perturbatie, dezelfde sporen, basislijn, begrensde stap en vervaging, dezelfde wereldzaden, dezelfde 16 breinzaden en dezelfde benchmarkset.

- **ANG met plasticiteit.** De wolk zoals sectie 2 en 4 haar beschrijven.
- **ANG met bevroren structuur.** Dezelfde beginwolk, maar snoeien, aangroei, groei en soortverandering staan uit. Het verschil met de vorige conditie is precies wat de structurele plasticiteit oplevert.
- **Gelaagd, één verborgen laag van 150.** Een vaste stapel lagen met hetzelfde parameterbudget (3000 verbindingen tegen 2996), alle verborgen knopen workers, geen terugkoppeling. Het kortste pad zintuig → knop is twee bogen, net als bij de wolk. Het verschil met de bevroren wolk is precies wat de topologie oplevert, want beide staan vast.
- **Gelaagd, twee lagen van 46.** Hetzelfde budget, maar een boog langer. Bij propagatiediepte één kost dat letterlijk één tijdstap extra tussen prikkel en actie.
- **Gelaagd, één laag van 60.** Evenveel neuronena als de wolk aan het begin, en daarmee nog geen half zo veel gewichten (1200).

conditie	benchmark, geloot	benchmark, argmax	laatste 20	verb.	pad	stappen	tijd
willekeurig beleid	0.0%	—	—	—	—	—	—
reactieve agent	38.6% ± 4.3	—	—	—	—	—	—
ANG, wolk met plasticiteit	65.4% ± 2.0	52.3% ± 3.0	87.2% ± 4.6	2996	2.00	159	7.0 s
ANG, wolk met bevroren structuur	67.5% ± 1.3	50.3% ± 2.7	90.9% ± 4.3	2650	2.00	154	5.8 s
gelaagd, 1 × 150	66.9% ± 0.5	40.9% ± 1.5	90.9% ± 3.5	3000	2.00	107	5.3 s
gelaagd, 2 × 46	62.4% ± 2.6	49.7% ± 2.6	81.6% ± 5.3	3036	3.00	168	7.2 s
gelaagd, 1 × 60	67.0% ± 1.0	42.8% ± 1.8	91.3% ± 4.0	1200	2.00	129	2.7 s

Wat de structuur oplevert: op deze taak niets

Het gelaagde netwerk doet het even goed als de wolk. Met hetzelfde parameterbudget en hetzelfde kortste pad haalt het 66.9% ± 0.5 tegen 67.5% ± 1.3 voor de bevroren wolk — -0.6 procentpunt, $p = 0.763$, verschil valt binnen de ruis. Ook een laag van zestig knopen, met minder dan de helft van de gewichten, komt op 67.0% ± 1.0. Op deze taak voegt de graafstructuur dus niets toe aan wat de leerregel al doet, en het parameterbudget doet er nauwelijks toe.

En de structurele plasticiteit evenmin. Snoeien, aangroei, neuronale groei en soortverandering samen uitzetten kost niets — de bevroren wolk scoort zelfs 2.1 procentpunt hoger ($p = 0.113$, verschil valt binnen de ruis). Het mechanisme dat het model zijn naam geeft, is op deze omgeving dus niet

aantoonbaar nuttig — het kost wel rekentijd (7.0 s tegen 5.8 s per run) en het vergroot de spreiding tussen zaden (± 2.0 tegen ± 1.3). Deze meting zegt alleen dat het geheel niets oplevert; sectie 10.7 splitst dat uit naar de afzonderlijke mechanismen.

Wat wél meetbaar is: padlengte

Eén structureel verschil komt er wel doorheen. Twee lagen van 46 hebben hetzelfde budget als één laag van 150, maar een boog meer tussen zintuig en knop, en scoren $62.4\% \pm 2.6$ — 5.1 procentpunt onder de bevroren wolk, $p = 0.003$, verschil is er echt. Dat is de enige conditie in deze tabel waar het verschil boven de ruis uitkomt. Bij propagatiediepte één is een boog een tijdstap, dus dit is geen verschil in capaciteit maar in *reactietijd*: het netwerk reageert een tik later op wat het ziet, en dat kost succes. Precies dat is de eigenschap waarop sectie 10.15 de resterende onderzoeksvraag baseert — maar zij pleit hier evengoed voor een ondiep gelaagd netwerk als voor een graaf.

De eerlijke samenvatting. Alles boven de reactieve ondergrens van 38.6% is op deze taak toe te schrijven aan de leerregel, niet aan de graaf. Wie wil laten zien dat een zichzelf herstructurerende topologie iets toevoegt, heeft een omgeving nodig waarin verschillende informatielatenties werkelijk nodig zijn; in een taak waarin het doel altijd zichtbaar is en één tussenlaag volstaat, is er niets te herstructureren dat de moeite loont. Dat is de aanleiding voor de tweede taak in sectie 10.8, en het is de reden dat de vraagstelling in sectie 10.15 smaller is dan waar dit werk mee begon.

10.5 Wat de schatter waard is, en wat het rekenwerk kost

Sectie 10.4 hield de leerregel vast en varieerde de topologie. Deze sectie doet het omgekeerde: dezelfde topologie, dezelfde spelregels, dezelfde 16 breinzaden en dezelfde benchmarkset, maar het verborgen leersignaal komt één keer uit node-perturbatie en één keer uit terugpropagatie. Alles daaromheen is gelijk gehouden: hetzelfde spoor met dezelfde λ , dezelfde lopende basislijn, dezelfde begrensde stap, dezelfde vervaging per poging, dezelfde Bernoulli-knoppen en dezelfde beloningen. Ook het startnetwerk is bit voor bit hetzelfde. Wat overblijft is de schatter, en dat is precies de vraag die de vergelijking met backpropagation hoort te beantwoorden.

Twee dingen maken de vergelijking pas eerlijk. Ten eerste draait elke conditie op *haar eigen* leersnelheid: de exacte gradiënt heeft een andere grootte dan een perturbatieschatting, en ANG's 0,008 is met de hand op ANG afgesteld. Zes leersnelheden, vier breinzaden per leersnelheid, gekozen op de goedkope toets van twintig werelden — nooit op de benchmarkset, want die is de meetlat en mag geen instellingen kiezen. De veegzaden liggen bovendien buiten de zaden waarop gemeten wordt, zodat de keuze niet de eigen ruis terugmeet. Ten tweede rekent elk gelaagd net zijn uitvoer binnen één spelstap uit (propagatiediepte gelijk aan zijn diepte), zodat de reactielatentie die in sectie 10.4 vijf procentpunt kostte hier geen rol speelt; de laatste regel van de tabel is de controle die dat nameet.

Eén gevolg daarvan meteen. Dezelfde veeg is ook op ANG zelf losgelaten, en die kwam niet uit op de met de hand afgestelde 0,008 maar op 0,004. Op de goedkope toets scheelde dat 4 procentpunt over vier zaden — ruim binnen de ruis, dus dit is geen ontdekking maar een gevolg van argmax over zes waarden. Het staat hier omdat de ANG-regel in deze tabel daardoor op een andere leersnelheid draait dan die in sectie 10.3 en 10.4, en dat mag een lezer niet hoeven raden.

conditie	η	benchmark, geloot	benchmark, argmax	laatste 20	gewichten
ANG, de wolk	0,004	$63.2\% \pm 3.0$	$52.7\% \pm 4.0$	$82.5\% \pm 5.3$	3068
MLP 16-16-4, perturbatie	0,008	$39.3\% \pm 5.3$	$37.1\% \pm 5.1$	$63.8\% \pm 4.5$	320
MLP 16-16-4, backprop	0,016	$66.7\% \pm 0.6$	$42.6\% \pm 1.7$	$91.6\% \pm 4.4$	320
MLP 16-32-32-4, perturbatie	0,004	$41.7\% \pm 4.9$	$41.1\% \pm 3.3$	$65.9\% \pm 6.1$	1664
MLP 16-32-32-4, backprop	0,008	$64.9\% \pm 1.1$	$42.3\% \pm 1.4$	$93.8\% \pm 4.2$	1664

conditie	η	benchmark, geloot	benchmark, argmax	laatste 20	gewichten
Elman-16, perturbatie	0,004	42.3% $\pm$ 5.0	40.1% $\pm$ 4.4	66.3% $\pm$ 5.0	576
Elman-16, backprop	0,008	66.3% $\pm$ 1.2	50.7% $\pm$ 2.0	92.2% $\pm$ 4.1	576
MLP 16-16-4, perturbatie, diepte 1	0,008	46.7% $\pm$ 5.2	40.5% $\pm$ 3.3	66.3% $\pm$ 4.8	320

Wat levert een exacte gradiënt op?

- **MLP 16-16-4.** 39.3% $\pm$ 5.3 met node-perturbatie tegen 66.7% $\pm$ 0.6 met de exacte gradiënt — +27.4 procentpunt, $p < 0,001$, verschil is er echt. Omgevingsstappen tot 80 % succes: 102.6 k tegen 7.9 k ($p < 0,001$, verschil is er echt).
- **MLP 16-32-32-4.** 41.7% $\pm$ 4.9 met node-perturbatie tegen 64.9% $\pm$ 1.1 met de exacte gradiënt — +23.2 procentpunt, $p < 0,001$, verschil is er echt. Omgevingsstappen tot 80 % succes: 100.7 k tegen 7.4 k ($p < 0,001$, verschil is er echt).
- **Elman-16.** 42.3% $\pm$ 5.0 met node-perturbatie tegen 66.3% $\pm$ 1.2 met de exacte gradiënt — +23.9 procentpunt, $p < 0,001$, verschil is er echt. Omgevingsstappen tot 80 % succes: 99.1 k tegen 8.3 k ($p < 0,001$, verschil is er echt).

Samengevat. Op 3 van de 3 netten scoort de exacte gradiënt aantoonbaar beter. Dat is wat er wordt opgegeven door geen backpropagation te gebruiken, uitgedrukt in de enige eenheid die telt: gedrag op onbekende werelden. Het kost wel een leerregel die niet meer lokaal is.

Een detail dat de tabel hieronder vleit. De drempel van 80 % wordt niet door elke run gehaald: MLP 16-16-4, perturbatie 12 van 16, MLP 16-32-32-4, perturbatie 13 van 16, Elman-16, perturbatie 14 van 16, MLP 16-16-4, perturbatie, diepte 1 13 van 16. De kolommen “tot 80 %” gemiddelden dus alleen over de runs die de drempel bereikten, wat de condities die hem vaak missen gunstiger laat lijken dan zij zijn. Dat zijn zonder uitzondering de perturbatiecondities; het aantal staat er daarom bij.

Hoeveel gewichten kost het missen van backpropagation? Deze tabel en die van sectie 10.4 laten zich naast elkaar leggen, want zij delen de benchmarkset. Met node-perturbatie haalt een verborgen laag van zestien knopen 39.3% $\pm$ 5.3, terwijl dezelfde leerregel op een laag van honderdvijftig — 3000 gewichten in plaats van 320 — op 66.9% $\pm$ 0.5 komt. Met terugpropagatie zijn die zestien knopen genoeg: 66.7% $\pm$ 0.6 bij 320 gewichten. Node-perturbatie heeft op deze taak dus ruwweg een orde van grootte meer parameters nodig om te halen wat een exacte gradiënt met een tiende daarvan haalt. Dat is een scherpere formulering van wat er wordt opgegeven dan een verschil in eindscore: niet zozeer het gedrag, maar de prijs in capaciteit.

Vier dingen die allemaal “efficiëntie” heten

De rest van dit werk sprak over efficiëntie zonder haar te tellen. Hieronder staan de vier grootheden die die naam dragen, apart. De eenheid is één kanten-bezoek: één keer een gewicht aanraken, bij het doorrekenen of bij het bijwerken. Een netwerk dat meer werk nodig heeft om te leren maar daarna goedkoper draait is een interessant resultaat — maar alleen als die kolommen los van elkaar gerapporteerd worden.

conditie	kanten per lerende stap	kanten per inferentiestap	omgevingsstappen tot 80 %	kanten tot 80 %	actieve verb.	tijd
ANG, de wolk	10.7 k	3.0 k	48.5 k	516.4 M	1664	7.1 s
MLP 16-16-4, perturbatie	1.9 k	640	102.6 k (12/16)	197.2 M	114	3.0 s
MLP 16-16-4, backprop	1.6 k	640	7.9 k	12.7 M	193	1.4 s
MLP 16-32-32-4, perturbatie	13.3 k	5.0 k	100.7 k (13/16)	1.3 G	915	10.4 s

conditie	kanten per lerende stap	kanten per inferentiestap	omgevingsstappen tot 80 %	kanten tot 80 %	actieve verb.	tijd
MLP 16-32-32-4, backprop	10.0 k	5.0 k	7.4 k	74.1 M	1121	3.5 s
Elman-16, perturbatie	3.5 k	1.2 k	99.1 k (14/16)	342.7 M	291	2.6 s
Elman-16, backprop	2.6 k	1.2 k	8.3 k	21.8 M	399	1.2 s
MLP 16-16-4, perturbatie, diepte 1	1.3 k	320	97.6 k (13/16)	125.1 M	113	1.3 s

De rekening. ANG heeft 10.7 k kanten-bezoeken nodig per lerende spelstap en 3.0 k per inferentiestap, en komt op 516.4 M kanten-bezoeken voordat het lopende succes de 80 % raakt. MLP 16-16-4, backprop doet dat met 12.7 M — een factor 40.6 goedkoper — bij een hógere benchmarkscore ($66.7\% \pm 0.6$ tegen $63.2\% \pm 3.0$). De hypothese dat een klein vast netwerk op deze taak op rekenkosten wint, is daarmee gemeten in plaats van vermoed, en zij komt uit. Dat is geen mislukking van het model maar een afbakening van waar het thuishoort: sectie 10.15 trekt die conclusie door naar de onderzoeksvraag zelf.

De controle op de reactielatentie. Hetzelfde net op propagatiediepte 1 in plaats van 2 — dus met één tijdstap vertraging tussen prikkel en knop, zoals de gelaagde condities in sectie 10.4 die hadden — haalt $46.7\% \pm 5.2$ tegen $39.3\% \pm 5.3$ (-7.4 procentpunt, $p = 0.062$, verschil valt binnen de ruis). De latentie verklaart hier dus niets van het verschil tussen de schatters; de vergelijking hierboven staat op zichzelf.

10.6 Vier ingrepen in de leerregel zelf

Sectie 10.4 hield de leerregel vast en varieerde de topologie; sectie 10.5 hield de topologie vast en varieerde de schatter. Deze sectie laat allebei staan — de wolk zoals zij is, node-perturbatie zoals zij is — en verandert alleen wat er omheen zit. Vier ingrepen, elk klein, elk apart aan en uit te zetten, elk op 12 breinzaden en dezelfde benchmarkset van 500 werelden.

- **Een toestandsafhankelijke criticus.** De basislijn in vergelijking 12 is één lopend gemiddelde over spelstappen: een getal zonder toestand. In een toestand die van zichzelf al slechter is dan gemiddeld ligt de beloning structureel onder die basislijn, en wordt dus elke actie daar afgestraft — ook de juiste. Daar staat hier een lineaire schatter $V(s) = w \cdot s + b$ tegenover, op dezelfde zestien sensoren die het netwerk ziet, getraind met $TD(0)$; het leersignaal wordt $r + \gamma V(s') - V(s)$. De schatter staat náást de graaf: er wordt niets door het netwerk teruggepropageerd, en de leerregel voor de verbindingen blijft woord voor woord die van sectie 3.
- **Schaarse perturbatie.** De variantie van node-perturbatie groeit met het aantal knopen dat tegelijk verstoord wordt. Per tik wordt daarom nog maar een kwart van de wolk verstoord; de rest krijgt die tik exact nul afwijking en dus geen spoor.
- **Een categorisch beleid.** De vier knoppen zijn onafhankelijke Bernoulli's, waardoor acties bestaan die zichzelf opheffen: op+neer, links+rechts, alle vier. Daar staat één softmax over negen elkaar uitsluitende acties tegenover — acht richtingen plus stilstaan — gescoord met de som van de knopingangen die bij die actie horen. Dat houdt de score-functie in dezelfde vorm, $(1[\text{ingedrukt}] - \text{randkans})/\tau$, en houdt het aantal uitvoerknopen op vier, zodat de conditie vergelijkbaar blijft met de rest van dit document.
- **De ontbrekende normalisatie.** Sectie 3.11 laat zien dat het wolkdeel van de update twee ordes te klein is ten opzichte van het knopdeel, en dat de standaardformulering van node-perturbatie daar een factor $1/\text{Var}(\xi)$ heeft die ANG mist. In 3.11 is die factor los bijgezet en stortte het leren in — maar zonder dat de leersnelheid opnieuw was afgesteld, terwijl η en die factor per

constructie samenhangen. Hier krijgt $g = 10$ wel zijn eigen leersnelheidsveeg, over een raster dat met $1/g$ meeschuift.

Zoals in sectie 10.5 draait elke conditie op *haar eigen* leersnelheid: zes waarden, vier breinzaden per waarde, gekozen op de goedkope toets van twintig werelden en nooit op de benchmarkset, met veegzaden buiten de meetzaden. Alle vier de ingrepen raken precies de grootheid waar η op afgesteld is — de schaal van het leersignaal, het aantal gewichten dat per tik een duw krijgt, of de vorm van de score-functie — dus zonder die veeg zou de tabel het afstellen meten in plaats van de ingreep.

conditie	η	benchmark, geloot	benchmark, argmax	sd tussen zaden	stappen tot 80 %
de regel van sectie 3	0,008	65.6% $\pm$ 2.6	53.5% $\pm$ 3.5	4.6 pp	19.0 k
+ criticus (TD(0))	0,004	60.9% $\pm$ 3.5	53.0% $\pm$ 3.6	6.2 pp	32.9 k
+ schaarse perturbatie ($\frac{1}{4}$)	0,016	66.6% $\pm$ 2.1	51.8% $\pm$ 3.8	3.7 pp	13.5 k
+ criticus + schaars	0,008	64.3% $\pm$ 2.7	54.9% $\pm$ 4.4	4.8 pp	14.6 k
+ categorisch beleid (9 acties)	0,002	68.8% $\pm$ 1.9	61.3% $\pm$ 3.3	3.4 pp	30.7 k
+ perturbGain ($g = 10$)	0,0008	33.3% $\pm$ 6.3	46.6% $\pm$ 5.3	11.1 pp	116.4 k (2/12)

Stappen tot 80 % is het aantal omgevingsstappen dat nodig was voordat het succes over de laatste twintig pogingen voor het eerst boven 80 % kwam: de maat voor hoe zuinig een leerregel met ervaring omgaat, los van waar zij uiteindelijk uitkomt. Waar een conditie die drempel niet in elke run haalt, staat tussen haakjes hoeveel runs hem wél haalden — het gemiddelde gaat alleen over die runs en vleit de conditie dus. De drempel telt pas zodra er werkelijk twintig pogingen achter dat gemiddelde zitten; zonder die eis is het aan het begin van een run een gemiddelde over één of twee pogingen, en kreeg een run waarvan de allereerste poging toevallig slaagde "de drempel gehaald na één poging". Dat gebeurde in 35 van de 256 runs en niet gelijk verdeeld over de condities. De maat is voor alle metingen in dit document opnieuw uit de bewaarde historie afgeleid, zonder iets opnieuw te trainen.

Wat de ingrepen opleveren

- **Criticus (TD(0)).** 60.9% $\pm$ 3.5 tegen 65.6% $\pm$ 2.6 voor de ongewijzigde regel — -4.7 procentpunt, $p = 0.053$, verschil valt binnen de ruis. Spreiding tussen de zaden 6.2 pp tegen 4.6 pp; omgevingsstappen tot 80 % succes 32.9 k tegen 19.0 k ($p = 0.030$, verschil is er echt).
- **Schaarse perturbatie ($\frac{1}{4}$).** 66.6% $\pm$ 2.1 tegen 65.6% $\pm$ 2.6 voor de ongewijzigde regel — +1.0 procentpunt, $p = 0.583$, verschil valt binnen de ruis. Spreiding tussen de zaden 3.7 pp tegen 4.6 pp; omgevingsstappen tot 80 % succes 13.5 k tegen 19.0 k ($p = 0.007$, verschil is er echt).
- **Criticus + schaars.** 64.3% $\pm$ 2.7 tegen 65.6% $\pm$ 2.6 voor de ongewijzigde regel — -1.3 procentpunt, $p = 0.603$, verschil valt binnen de ruis. Spreiding tussen de zaden 4.8 pp tegen 4.6 pp; omgevingsstappen tot 80 % succes 14.6 k tegen 19.0 k ($p = 0.046$, verschil is er echt).
- **Categorisch beleid (9 acties).** 68.8% $\pm$ 1.9 tegen 65.6% $\pm$ 2.6 voor de ongewijzigde regel — +3.2 procentpunt, $p = 0.112$, verschil valt binnen de ruis. Spreiding tussen de zaden 3.4 pp tegen 4.6 pp; omgevingsstappen tot 80 % succes 30.7 k tegen 19.0 k ($p = 0.035$, verschil is er echt).
- **PerturbGain ($g = 10$).** 33.3% $\pm$ 6.3 tegen 65.6% $\pm$ 2.6 voor de ongewijzigde regel — -32.3 procentpunt, $p < 0.001$, verschil is er echt. Spreiding tussen de zaden 11.1 pp tegen 4.6 pp; omgevingsstappen tot 80 % succes 116.4 k tegen 19.0 k ($p = 0.036$, verschil is er echt).

Op de eindscore verandert er weinig. Wat er op die maat boven de ruis uitkomt is dat perturbGain ($g = 10$) de score aantoonbaar verlaagt. De overige verschillen vallen binnen de meetruis van 12 zaden, en dat betekent dat ze niet aan te tonen zijn — niet dat ze er niet zijn. Een geleerde basislijn, de meest voor de hand liggende verbetering aan een REINFORCE-achtige regel, doet op deze taak dus niets: de

beperking zit niet in de basislijn. Maar de eindscore is niet de enige maat, en op twee andere gebeurt er wél iets.

Wat er wél uitkomt: schaarse perturbatie is zuiniger met ervaring

Per tik nog maar een kwart van de wolk verstoren levert dezelfde eindscore op ($66.6\% \pm 2.1$ tegen $65.6\% \pm 2.6$, $p = 0.583$, verschil valt binnen de ruis), maar bereikt haar met 13.5 k omgevingsstappen in plaats van 19.0 k — een factor 1.4 minder ervaring, $p = 0.007$, verschil is er echt. In kanten-bezoeken is het verschil even groot (144.9 M tegen 200.1 M), want een spelstap kost in beide condities even veel rekenwerk: het masker bespaart geen werk in de propagatie, het maakt het leersignaal minder ruizig. De combinatie met de criticus laat dat effect staan (14.6 k stappen, $p = 0.046$), wat bevestigt dat het van de schaarse perturbatie komt en niet van de criticus. Dit is de enige plek in dit document waar een ingreep in de leerregel iets oplevert in plaats van kost, en het is precies waar de theorie het voorspelt: de variantie van een perturbatieschatter groeit met het aantal knopen dat tegelijk beweegt, dus minder tegelijk verstoren maakt elke afzonderlijke toewijzing scherper.

Waarom het de eindscore niet raakt. Vijfhonderd pogingen zijn ruim genoeg om ook met het ruizige signaal uit te leren; de zuinigere variant is er alleen eerder. Dat maakt de winst niet minder echt, maar wel van een andere soort: zij telt in een omgeving waarin ervaring duur is — een robot, een simulatie die traag draait, een systeem dat online leert — en niet in een spel dat je een miljoen keer kunt spelen.

En een tweede: het categorische beleid heeft het toeval minder nodig

Sectie 10.2 rapporteert dat argmax — altijd de waarschijnlijkste knop indrukken — 12.1 procentpunt kost ten opzichte van het gelote beleid, en dat het toeval dus geen ruis is die je er bij het toetsen netjes uit haalt maar onderdeel van de strategie is geworden. Met negen elkaar uitsluitende acties zakt dat gat naar 7.5 procentpunt: de argmax-score stijgt van $53.5\% \pm 3.5$ naar $61.3\% \pm 3.3$ (+7.8 pp, $p = 0.009$, verschil is er echt), terwijl de gelote score binnen de ruis gelijk blijft (+3.2 pp, $p = 0.112$). Dat is precies wat je verwacht als een deel van het oude gat ontstond doordat onafhankelijke knoppen elkaar kunnen opheffen: onder argmax is “op én neer” een echte, volledig verlamme actie, terwijl het gelote beleid daar met kans omheen komt. Neem je die acties uit de verzameling weg, dan heeft het beleid het toeval minder nodig.

De keerzijde. Het categorische beleid heeft 30.7 k omgevingsstappen nodig om 80 % te halen tegen 19.0 k voor de onafhankelijke knoppen. Negentien acties tegen zestien combinaties is een kleinere ruimte, maar de exploratie erin is grover: één trekking per tik in plaats van vier, en dus minder fijnmazige variatie om aan toe te schrijven.

En de criticus, waar dit pakket mee begon, levert niets op. De verwachting was minder spreiding tussen de zaden en een gelijke of hogere score. Gemeten: $60.9\% \pm 3.5$ tegen $65.6\% \pm 2.6$ (−4.7 pp, $p = 0.053$, verschil valt binnen de ruis), een spreiding tussen de zaden die juist gróter is (6.2 tegen 4.6 pp), en 32.9 k omgevingsstappen tot 80 % tegen 19.0 k ($p = 0.030$). Twee verklaringen liggen voor de hand en de meting kiest er niet tussen. De eerste is dat een lineaire waardefunctie op zestien raycast-sensoren de waarde van een toestand in deze wereld eenvoudig niet kan uitdrukken: of een positie goed is hangt af van of er een obstakel tussen agent en doel staat, en dat is geen lineaire functie van de zintuigen. De tweede is dat de criticus zelf moet leren en in het begin dus ruis toevoegt in plaats van weghaalt, terwijl de lopende basislijn er meteen staat. Wat de meting wél uitsluit is de simpelste diagnose: dat het probleem in de toestandsloze basislijn zat. Dat zat het niet.

Toewijzing binnen het pakket. De combinatie van criticus en schaarse perturbatie verschilt niet aantoonbaar van de criticus alleen ($p = 0.194$) en niet aantoonbaar van de schaarse perturbatie alleen ($p = 0.204$). De twee ingrepen versterken elkaar op deze taak dus niet; ze zijn samen gemeten omdat ze in het werkplan als paar stonden, en apart omdat een verschil anders niet toe te wijzen was geweest.

En de schaalfout uit sectie 3.11? Met een eigen leersnelheidsveeg komt $g = 10$ uit op $\eta = 0,0008$ en op $33.3\% \pm 6.3$ — −32.3 procentpunt tegen de ongewijzigde regel, $p < 0,001$, verschil is er echt. Sectie

3.11 mat dezelfde ingreep zonder eigen veeg en zag de score instorten; met een leersnelheid die meeschuift is dat beeld milder maar niet anders. De les is dezelfde als daar: η , de stapbegrenzing en de schaal van het wolkdeel zijn één samenhangend geheel, en één ervan verzetten terwijl de andere blijft staan meet vooral de ontregeling.

Ijk op de eerdere reeks. De ongewijzigde regel is voor deze tabel opnieuw gedraaid en reproduceert 12 van de 12 runs van de referentiemeting uit sectie 10.3 tot op de zes decimalen die runs.csv bewaart. Het inbouwen van de vier schakelaars heeft de leerregel met alles uit dus niet geraakt — dat is geen vanzelfsprekendheid, want een schakelaar die per ongeluk één trekking uit de toevalsreeks haalt zou elke run een andere kant op sturen zonder dat er iets aan mis lijkt.

10.7 Wat elk onderdeel bijdraagt: de ablatiereeks

Sectie 10.4 laat zien dat de structurele plasticiteit als geheel niets oplevert, maar niet welk van de mechanismen daaraan schuldig is; sectie 10.5 en 10.6 zeggen niets over de soorten neuronen. Deze reeks haalt er één onderdeel tegelijk uit en laat de rest staan: de drie gespecialiseerde soorten neuronen, de vier vormen van structurele plasticiteit, de bedradingsgrammatica, en als uiterste de volledig bevroren structuur waarin alleen de gewichten nog leren. 16 breinzaden per conditie, 500 pogingen per run, dezelfde benchmarkset van 500 werelden, en dezelfde wereldzaden.

Anders dan in sectie 10.6 krijgt geen enkele conditie hier een eigen leersnelheid. Daar was die veeg nodig omdat alle vier de ingrepen precies de grootte raakten waar η op afgesteld is. Een ablatie doet dat niet: een soort neuronen weglaten of het snoeien uitzetten verandert de graaf, niet de schaal van de update. η staat dus voor alle tien condities op 0,008. Dat is een keuze met een prijs — het blijft denkbaar dat een ablatie met eigen afstelling beter uitkomt — en die prijs staat in sectie 9.

Negen condities tegen dezelfde referentie is een familie. Bij negen onafhankelijke toetsen op $p < 0,05$ is de kans dat er minstens één toevallig uitkomt ongeveer 37 %, en dan is de tabel een lijst met valse vondsten. Elke maat krijgt daarom een Holm-correctie over de negen vergelijkingen; hieronder staan de ruwe en de gecorrigeerde waarde naast elkaar, en de tekst baseert zich op de gecorrigeerde.

conditie	benchmark, geloot	Δ (pp)	p	Holm	stappen tot 80 %
het volle model	65.4% $\pm$ 2.0	–	–	–	18.3 k
geen geheugen-neuronen	65.9% $\pm$ 1.1	+0.5	p = 0.734	1.000	16.9 k
geen reflex-neuronen	65.2% $\pm$ 1.9	–0.2	p = 0.925	1.000	20.8 k
geen invoer-neuronen	60.4% $\pm$ 6.0	–5.0	p = 0.200	1.000	24.7 k (15/16)
geen snoeien	66.6% $\pm$ 2.0	+1.2	p = 0.300	1.000	14.6 k
geen aangroei van verbindingen	63.9% $\pm$ 2.5	–1.5	p = 0.510	1.000	20.1 k
geen neuronale groei	64.4% $\pm$ 2.6	–1.0	p = 0.734	1.000	16.3 k
geen hertypering	65.1% $\pm$ 2.0	–0.3	p = 0.865	1.000	18.3 k
strengte invoer	41.5% $\pm$ 8.5	–23.9	p < 0,001	< 0,001	58.1 k (12/16)
vaste structuur, alleen gewichten	67.5% $\pm$ 1.3	+2.1	p = 0.113	0.907	15.9 k

Elke conditie is nagerekend op de vraag of zij werkelijk weglaat wat zij belooft. Dat is bij een ablatiereeks geen formaliteit: een conditie die het onderdeel niet echt uitzet levert een nette tabelregel op die zegt dat het onderdeel er niet toe doet. Per run is uit de weggeschreven kolommen gecontroleerd dat er nul geheugen-, reflex- of invoer-neuronen zijn, nul verbindingen gesnoeid, nul bijgegroeid, nul neuronen bijgekomen of nul hertyperingen — al naar gelang de conditie. De strenge invoerregel is niet uit die kolommen af te lezen en is op de graaf zelf gecontroleerd: met de vlag aan landt elke kant vanaf een invoer-node op een invoer-neuron, met de vlag uit een klein deel. Bij het

schrijven van deze reeks bleek dat die vlag tot dan toe alleen uit het scherm kwam en niet uit de configuratie van de experimentloper; de conditie was met andere woorden meetbaar leeg geweest. Dat is hersteld, en de reeks van sectie 10.2 reproduceert daarna nog steeds bit voor bit.

Wat de reeks laat zien

- **Geen geheugen-neuronen.** $65.9\% \pm 1.1$ tegen $65.4\% \pm 2.0$ voor het volle model — +0.5 procentpunt, $p = 0.734$, na Holm 1.000: binnen de ruis. Onder argmax $44.8\% \pm 2.2$ tegen $52.3\% \pm 3.0$ (-7.6 pp, na Holm 0.017). Actieve verbindingen 1492 tegen 1446, kortste pad 2.00 tegen 2.00; omgevingsstappen tot 80 % succes 16.9 k tegen 18.3 k ($p = 0.235$, na Holm 1.000).
- **Geen reflex-neuronen.** $65.2\% \pm 1.9$ tegen $65.4\% \pm 2.0$ voor het volle model — -0.2 procentpunt, $p = 0.925$, na Holm 1.000: binnen de ruis. Onder argmax $49.4\% \pm 3.3$ tegen $52.3\% \pm 3.0$ (-2.9 pp, na Holm 1.000). Actieve verbindingen 1406 tegen 1446, kortste pad 2.00 tegen 2.00; omgevingsstappen tot 80 % succes 20.8 k tegen 18.3 k ($p = 0.777$, na Holm 1.000).
- **Geen invoer-neuronen.** $60.4\% \pm 6.0$ tegen $65.4\% \pm 2.0$ voor het volle model — -5.0 procentpunt, $p = 0.200$, na Holm 1.000: binnen de ruis. Onder argmax $48.4\% \pm 4.8$ tegen $52.3\% \pm 3.0$ (-3.9 pp, na Holm 1.000). Actieve verbindingen 1454 tegen 1446, kortste pad 2.00 tegen 2.00; omgevingsstappen tot 80 % succes 24.7 k tegen 18.3 k ($p = 0.828$, na Holm 1.000).
- **Geen snoeien.** $66.6\% \pm 2.0$ tegen $65.4\% \pm 2.0$ voor het volle model — +1.2 procentpunt, $p = 0.300$, na Holm 1.000: binnen de ruis. Onder argmax $49.3\% \pm 3.2$ tegen $52.3\% \pm 3.0$ (-3.1 pp, na Holm 1.000). Actieve verbindingen 1575 tegen 1446, kortste pad 2.00 tegen 2.00; omgevingsstappen tot 80 % succes 14.6 k tegen 18.3 k ($p = 0.073$, na Holm 0.541).
- **Geen aangroei van verbindingen.** $63.9\% \pm 2.5$ tegen $65.4\% \pm 2.0$ voor het volle model — -1.5 procentpunt, $p = 0.510$, na Holm 1.000: binnen de ruis. Onder argmax $51.7\% \pm 3.6$ tegen $52.3\% \pm 3.0$ (-0.6 pp, na Holm 1.000). Actieve verbindingen 1507 tegen 1446, kortste pad 2.00 tegen 2.00; omgevingsstappen tot 80 % succes 20.1 k tegen 18.3 k ($p = 0.925$, na Holm 1.000).
- **Geen neuronale groei.** $64.4\% \pm 2.6$ tegen $65.4\% \pm 2.0$ voor het volle model — -1.0 procentpunt, $p = 0.734$, na Holm 1.000: binnen de ruis. Onder argmax $52.0\% \pm 3.4$ tegen $52.3\% \pm 3.0$ (-0.3 pp, na Holm 1.000). Actieve verbindingen 1177 tegen 1446, kortste pad 2.00 tegen 2.00; omgevingsstappen tot 80 % succes 16.3 k tegen 18.3 k ($p = 0.396$, na Holm 1.000).
- **Geen hertypering.** $65.1\% \pm 2.0$ tegen $65.4\% \pm 2.0$ voor het volle model — -0.3 procentpunt, $p = 0.865$, na Holm 1.000: binnen de ruis. Onder argmax $48.8\% \pm 3.7$ tegen $52.3\% \pm 3.0$ (-3.5 pp, na Holm 1.000). Actieve verbindingen 1513 tegen 1446, kortste pad 2.00 tegen 2.00; omgevingsstappen tot 80 % succes 18.3 k tegen 18.3 k ($p = 0.486$, na Holm 1.000).
- **Streng invoer.** $41.5\% \pm 8.5$ tegen $65.4\% \pm 2.0$ voor het volle model — -23.9 procentpunt, $p < 0.001$, na Holm < 0.001 : sterk. Onder argmax $43.1\% \pm 7.0$ tegen $52.3\% \pm 3.0$ (-9.3 pp, na Holm 0.612). Actieve verbindingen 1347 tegen 1446, kortste pad 2.00 tegen 2.00; omgevingsstappen tot 80 % succes 58.1 k tegen 18.3 k ($p = 0.007$, na Holm 0.060).
- **Vaste structuur, alleen gewichten.** $67.5\% \pm 1.3$ tegen $65.4\% \pm 2.0$ voor het volle model — +2.1 procentpunt, $p = 0.113$, na Holm 0.907: binnen de ruis. Onder argmax $50.3\% \pm 2.7$ tegen $52.3\% \pm 3.0$ (-2.0 pp, na Holm 1.000). Actieve verbindingen 1278 tegen 1446, kortste pad 2.00 tegen 2.00; omgevingsstappen tot 80 % succes 15.9 k tegen 18.3 k ($p = 0.068$, na Holm 0.541).

Van de negen onderdelen laat er één na correctie een spoor na op de eindscore. Aantoonbaar slechter dan het volle model: strenge invoer. Op het aantal omgevingsstappen tot 80 % succes komt na correctie niets boven de ruis uit. Wat er binnen de ruis valt is niet aantoonbaar afwezig, alleen niet aantoonbaar aanwezig: bij 16 zaden en een spreiding van enkele procentpunten tussen zaden is een effect van een paar procentpunt niet te zien.

Eén onderdeel raakt niet de gelote score maar de vorm van het beleid. De conditie geen geheugen-neuronen scoort onder het gelote beleid gelijk aan het volle model, maar onder argmax 7.6 procentpunt lager (na Holm 0.017). Argmax legt het beleid vast op zijn eigen voorkeur; de gelote score middelt daaroverheen. Een verschil dat alleen onder argmax zichtbaar is, zegt dus dat de voorkeur zelf minder scherp is geworden terwijl de verdeling eromheen even goed blijft presteren. Dat past bij wat sectie 10.6 al liet zien: op deze taak is het toeval onderdeel van de strategie geworden, en een maat die dat toeval wegneemt meet iets anders dan de gemiddelde prestatie.

De uitkomst hoort bij de taak, niet bij het model in het algemeen. In deze taak is het doel altijd zichtbaar, dus er valt niets te onthouden; dat de geheugen-neuronen weglaten weinig kost is daarmee geen uitspraak over geheugen maar over deze omgeving. Hetzelfde geldt voor de reflex-neuronen: er is geen prikkel die binnen één tik beantwoord moet worden, dus een korte boog levert niets op wat een lange niet ook levert. Precies daarom is de tweede taak in sectie 10.8 geen bijzaak: zij is de eerste opzet waarin deze ablaties een uitslag kunnen geven die iets over het model zegt in plaats van over het spel.

10.8 De as van waarneembaarheid: wat er gebeurt als het doel wegvalt

Elke meting tot hier gebruikt een taak waarin het doel de hele poging zichtbaar is. In zo'n taak valt er niets te onthouden, en dus zegt geen van de voorgaande secties iets over geheugen — ook sectie 10.7 niet, waar het weglaten van de geheugen-neuronen op de gelote score niets kostte. Dat is geen resultaat over geheugen maar over deze omgeving. Deze sectie verandert daarom de omgeving, en wel met één knop in dezelfde omgeving in plaats van met een tweede spel: het doel is tien spelstappen te zien, daarna een instelbaar aantal stappen niet, en zo door. Op nul is het de taak van alle voorgaande secties, letterlijk ongewijzigd — dat is bit voor bit nagemeten tegen de referentiemeting van sectie 10.3. De beloning verandert niet mee: het spel weet nog steeds waar het doel staat. Wat er verandert is uitsluitend de waarneembaarheid, en daarmee wordt de opgave deels waarneembaar.

Eerst een variant die is afgefallen, want dat hoort erbij. De eerste opzet verborg het doel permanent na k stappen. Bij $k = 80$ zakte ANG naar enkele procenten en was er niets meer te vergelijken. De diagnose is de moeite van het vasthouden waard: permanent verbergen vraagt geen geheugen maar koppelnavigatie. Na tachtig blinde stappen een punt raken met de precisie van een doelstraal is een ander en veel moeilijker probleem dan informatie vasthouden, en een vloer van nul meet niets. De knipperende vorm houdt de opgave oplosbaar: de agent moet een onderbreking overbruggen en krijgt daarna weer een ijkpunt.

Een geheugenmaat die niet aan dit model hangt

De structuurmaten van sectie 6 zijn ongeschikt om te bewijzen dat er geheugen ontstaat. Een geheugen-neuron heeft in dit model per definitie een zelfverbinding, dus zelfverbindingen tellen meet de bedradingsregel en niet het gedrag. Daarom wordt hier een *interventie* gemeten. Dezelfde getrainde agent speelt honderd verse werelden twee keer met dezelfde toevalsreeks: één keer met het doel de eerste twintig stappen zichtbaar en daarna niet meer, en één keer met het doel dat nooit zichtbaar is geweest. Het enige verschil tussen de twee is informatie die de agent ooit gehad heeft. Per stap na het blinderen wordt de cosinus gemeten tussen de werkelijke verplaatsing en de richting waarin het doel staat; de *geheugenhorizon* is het aantal stappen dat de eerste run de tweede blijft verslaan, per vertraging gepaard en met een marge van 0,05. Nul betekent niet "geen geheugen-neuronen" maar "geen gedrag dat op onthouden lijkt" — een uitspraak die te weerleggen is, en die op een vast recurrent net met exact dezelfde code te meten valt.

architectuur	A (altijd zicht)	B-10 (10 donker)	B-20 (20 donker)	B-40 (40 donker)
ANG, met structurele plasticiteit	65.6% ± 2.6	27.4% ± 6.1	9.9% ± 1.9	2.8% ± 1.0
ANG, structuur bevroren	67.5% ± 1.2	31.2% ± 5.2	13.7% ± 2.4	5.4% ± 1.5
vast net zonder terugkoppeling, backprop	66.7% ± 0.6	65.2% ± 2.5	26.1% ± 2.0	14.5% ± 1.6
vast recurrent net, backprop afgekapt op één tik	66.6% ± 1.5	77.8% ± 1.5	75.4% ± 3.5	39.8% ± 5.3
ANG zonder neuronsoorten	58.5% ± 4.5	14.9% ± 3.0	10.1% ± 1.0	5.0% ± 0.9
geheugenhorizon (stappen)	A	B-10	B-20	B-40
ANG, met structurele plasticiteit	25.3	17.5	7.5	2.3
ANG, structuur bevroren	16.3	15.1	8.1	3.7
vast net zonder terugkoppeling, backprop	0.0	0.0	0.0	0.0
vast recurrent net, backprop afgekapt op één tik	21.5	43.3	41.7	29.3
ANG zonder neuronsoorten	6.0	3.8	2.9	1.3

Welke vergelijking de conclusie draagt. De vier architecturen verschillen op meer dan één as tegelijk: de vaste netten rekenen hun uitvoer in twee propagatiestappen uit en leren met terugpropagatie, ANG doet één stap en schat het verborgen leersignaal met node-perturbatie. Het gat tussen ANG en het vaste recurrente net is dus verward met die twee verschillen, en sectie 10.5 heeft ze allebei al beziferd. De vergelijking die de conclusie van deze sectie draagt is een andere en is wél schoon: *ANG tegen dezelfde graaf met bevroren structuur*. Zelfde topologie, zelfde propagatiediepte, zelfde schatter, zelfde zaden — het enige verschil is of de structuur nog mag veranderen.

Over de leersnelheden. Op de stand zonder knippen draait elke architectuur op de waarde die de veeg van sectie 10.5 of 10.6 voor haar koos. Op elke knipperstand hebben ANG en de bevroren variant een eigen veeg gekregen — apart per stand, op de goedkope toets van twintig werelden en nooit op de benchmark, met veegzaden buiten de meetzaden — omdat de uitkomst hieronder in het nadeel van ANG uitvalt en zo'n uitkomst niet op andermans afstelling mag rusten. Dat het per stand moest, is zelf een waarneming: één veeg in het midden van de as leverde een waarde op die op een andere stand slechter was dan de oorspronkelijke. De vaste basislijnen hebben die veeg niet gekregen en staan dus mogelijk onder hun beste waarde. Dat werkt in het voordeel van ANG en maakt de conclusie hieronder conservatief.

De maat werkt: een net zonder terugkoppeling haalt horizon nul

De blinderingsproef geeft het geheugenloze net op elke stand van de as een horizon van exact 0.0 stappen, en het vaste recurrente net 21.5, 43.3, 41.7, 29.3 stappen over de vier standen. Dat is precies wat een geheugenmaat hoort te doen: een architectuur die per constructie geen toestand meedraagt kan de controle niet verslaan, en een architectuur die dat wel doet, doet het meetbaar. De maat is daarmee bruikbaar als instrument, los van dit model — zij vraagt niets over hoe het geheugen geïmplementeerd is en telt geen zelfverbindingen.

Wat de as laat zien

- **10 stappen donker.** ANG 27.4% ± 6.1, dezelfde graaf met bevroren structuur 31.2% ± 5.2 ($p = 0.214$, na Holm 0.214); het vaste recurrente net 77.8% ± 1.5 (ANG tegen dat net: $p < 0,001$, na Holm $< 0,001$).

- **20 stappen donker.** ANG $9.9\% \pm 1.9$, dezelfde graaf met bevroren structuur $13.7\% \pm 2.4$ ($p = 0.024$, na Holm 0.024); het vaste recurrente net $75.4\% \pm 3.5$ (ANG tegen dat net: $p < 0,001$, na Holm $< 0,001$).
- **40 stappen donker.** ANG $2.8\% \pm 1.0$, dezelfde graaf met bevroren structuur $5.4\% \pm 1.5$ ($p = 0.010$, na Holm 0.010); het vaste recurrente net $39.8\% \pm 5.3$ (ANG tegen dat net: $p < 0,001$, na Holm $< 0,001$).

De uitkomst gaat de andere kant op dan de hypothese. De verwachting, vooraf in de repository vastgelegd, was dat het voordeel van structurele plasticiteit zou groeien zodra de taak iets te onthouden geeft. Gemeten wordt het omgekeerde. Op 20 stappen donker en 40 stappen donker scoort de bevroren variant aantoonbaar hoger dan dezelfde graaf met plasticiteit (3.8 procentpunt, na Holm 0.024 ; 2.5 procentpunt, na Holm 0.010), terwijl het verschil zonder knippen binnen de ruis valt. Structurele plasticiteit is op deze as dus geen voordeel dat nog moest opduiken, maar een kostenpost die zichtbaar wordt zodra de invoer niet meer voortdurend beschikbaar is.

Wat hier niet uit volgt. Dat het verschil groter wordt naarmate de donkere periode langer duurt, is met deze aantallen niet aan te tonen: de gepaarde vergelijking van het verschil per zaad tussen de stand zonder knippen en de knipperstanden geeft $p = 0.371$, $p = 0.194$, $p = 0.624$. De uitspraak die de data draagt is daarom de zwakkere en de preciezere: het verschil is er op de standen waar het gemeten is, en niet dat het meegroeit met de druk. Wie dat laatste wil weten heeft meer zaden nodig.

Het scherpste detail zit in de geheugenmaat zelf. ANG haalt op de taak zonder knippen een geheugenhorizon van 25.3 stappen — hoger dan het vaste recurrente net, en dat is opmerkelijk voor een taak waarin onthouden niets oplevert. Zodra de taak het wél vraagt, zakt die horizon naar 2.3. Het vaste recurrente net doet precies het omgekeerde: daar stijgt de horizon zodra de informatie wegvalt. De architectuur met geheugen-neuronen verliest haar geheugengedrag dus juist onder geheugendruk, en de architectuur zonder zulke neuronen ontwikkelt het. Dat is de duidelijkste aanwijzing in dit hele document dat de neuronsoorten van dit model namen zijn en geen functies.

Een tweede waarneming die om verklaring vraagt. Het vaste recurrente net gaat op de milde knipperstand niet achteruit maar vooruit: $66.6\% \pm 1.5$ met permanent zicht tegen $77.8\% \pm 1.5$ met tien stappen donker. Een plausibele verklaring is dat het wegvallen van de doelinvoer het beleid dwingt tot een koers in plaats van tot voortdurend bijsturen; sectie 10.2 en 10.6 lieten al zien dat het toeval in dit beleid onderdeel van de strategie is geworden. Dat is een hypothese en geen bevinding. Zij is te toetsen door de gemiddelde padlengte per geslaagde poging tussen de standen te vergelijken, en dat gebeurt in een volgende versie.

Zegt de functionele maat meer dan de structurele telling?

maat	Spearman ρ met de benchmarkscore	n
actieve verbindingen (structureel)	-0.56	180
geheugenhorizon (functioneel)	0.48	180
aantal geheugen-neuronen (structureel)	-0.39	180
aantal reflexbogen (structureel)	-0.34	180
aantal lussen (structureel)	0.25	180
koersbehoud na blinderen (functioneel)	0.10	180

Deze tabel moet met zorg gelezen worden. Zij gaat over alle runs op de knipperstanden samen, en die runs komen uit vier architecturen die op meer dan één as tegelijk verschillen. Een structurele telling als het aantal geheugen-neuronen correleert hier negatief met de score, maar dat komt doordat alleen ANG zulke neuronen heeft en ANG op deze standen het laagst scoort: de correlatie meet welke architectuur een run is, niet wat de structuur doet. Datzelfde voorbehoud geldt voor de positieve correlatie van de geheugenhorizon. Wat de tabel wél laat zien is dat de functionele maat de enige is die

in de goede richting wijst zonder van de neuronsoorten af te hangen — en dat is precies de reden dat het meetprogramma ernaartoe verschoven is. De ablatiereeks van sectie 10.7 blijft de interventie naast deze correlatie; correlatie en ablatie samen zeggen meer dan elk apart, en een correlatie binnen één architectuur is de volgende stap.

Dat voorbehoud is inmiddels gemeten, en het was terecht. Sectie 10.10 herhaalt deze correlaties binnen alleen de ang-runs van deze as — dezelfde architectuur, alleen de taakstand verschilt — en daar valt het grootste verband grotendeels weg: wat hier als een stevige samenhang oogt, is voor een flink deel de taakstand die zowel de structuur als de score meebeweegt. De tabel hierboven blijft dus staan als beschrijving van deze verzameling runs, maar zij mag niet als bewijs voor een structuur-gedragrelatie gelezen worden, ook niet in de regels waar het teken toevallig klopt.

10.9 De omslagproef: een omslag binnen één leven

Sectie 10.8 traint elke architectuur apart op elke stand van de as en vergelijkt eindprestaties. Over aanpassingsvermogen zegt dat niets: een vast netwerk dat je apart op twee taken traint krijgt óók twee verschillende gewichtssets. Wat een vaste architectuur principieel niet heeft, is de mogelijkheid haar rekenstructuur te verbouwen terwijl het leven doorloopt — en na de secties 10.4 tot en met 10.8 is dat het laatste argument voor dit model dat nog niet gemeten was. Deze sectie meet het, in de enige opzet waarin het meetbaar is: één doorlopend leven van 900 pogingen waarin de omgeving twee keer omslaat, zonder waarschuwing, zonder reset, en zonder dat het brein te horen krijgt dat er iets veranderd is.

pogingen	omgeving
0–299	het doel is altijd zichtbaar
300–599	het doel knippert: 10 stappen zichtbaar, 20 stappen niet
600–899	het doel is altijd zichtbaar

Het brein, de gewichten, de sporen, de lopende basislijn en de exploratieafbouw lopen over alle drie de fasen door; alleen de omgeving schakelt. De exploratie loopt over het *hële* leven terug en begint niet per fase opnieuw — zou zij dat wel doen, dan kreeg elke omslag er gratis een portie exploratiedrift bij en zou de hersteltijd die portie meten in plaats van het aanpassingsvermogen. Om dezelfde reden schakelt ook de leersnelheid niet mee: het brein weet niet dat de omgeving omslaat, dus mag de afstelling dat ook niet weten. Dat ANG de middenfase niet gaat beheersen is uit sectie 10.8 al bekend en is hier geen bezwaar: de middenfase is een verstoring, en de vraag is hoe het systeem ermee omgaat en ervan herstelt — niet of het haar leert.

Vooraf vastgelegd. De fasen, de condities en vijf voorspellingen met een uitgeschreven waar- én onwaar-tak staan in de repository, gecommitt vóóordat de eerste run gedraaid had. Dat is hier extra nodig, want dit is de laatste meting waarin het model nog iets kon laten zien wat een vaste architectuur niet heeft — en juist dan is de verleiding het grootst om achteraf een gunstige lezing te kiezen. Alle voorspellingen kwamen uit in hun onwaar-tak.

Het leven in vier meetpunten

conditie	einde A1	op B tijdens B	op A tijdens B	einde A2
ANG, met structurele plasticiteit	56.9% ± 6.2	15.3% ± 2.9	43.1% ± 8.2	64.1% ± 3.0
ANG, structuur bevroren	61.3% ± 4.9	16.2% ± 2.9	48.6% ± 6.4	68.5% ± 2.4
ANG, wel plasticiteit maar niet snoeien	62.9% ± 3.8	17.4% ± 2.4	51.3% ± 6.2	70.0% ± 1.4
vast recurrent net, backprop afgekapt op één tik	70.3% ± 2.1	64.0% ± 6.5	68.1% ± 1.6	62.4% ± 2.3

conditie	einde A1	op B tijdens B	op A tijdens B	einde A2
vast net zonder terugkoppeling, backprop	68.5% ± 2.1	19.0% ± 1.3	69.2% ± 2.0	67.3% ± 1.5

Hoe hersteltijd gedefinieerd is. Het plateau van de eerste fase is het gemiddelde succes over de laatste 50 pogingen van die fase. Hersteld heet een leven op de eerste poging ná de terugslag waar dat succes weer boven 95 % van dat plateau ligt. Wordt dat binnen de derde fase niet gehaald, dan is de waarneming gecensureerd: zij krijgt in de rangtoets een waarde boven alles wat wél hersteld is en telt in geen enkel gemiddelde mee. In deze reeks is dat niet voorgekomen — alle 60 levens herstellen binnen de derde fase, er is dus niets gecensureerd.

conditie	hersteltijd (pogingen)	behoud (procentpunt)	terugwinst (procentpunt)
ANG, met structurele plasticiteit	26.8	-13.8	7.2
ANG, structuur bevroren	32.4	-12.7	7.3
ANG, wel plasticiteit maar niet snoeien	21.3	-11.6	7.1
vast recurrent net, backprop afgekapt op één tik	1.5	-2.2	-7.9
vast net zonder terugkoppeling, backprop	12.3	0.7	-1.2

Behoud is wat er van taak A over is na de knipperfase: de benchmark op A aan het eind van fase B min die aan het eind van fase A1. Negatief is vergeten. Terugwinst is waar het leven aan het eind staat ten opzichte van vóór de omslag.

Wat de proef laat zien

1. Er is geen herstelvoordeel. De vergelijking die de vraag beantwoordt is ANG tegen dezelfde graaf met bevroren structuur: 26.8 tegen 32.4 pogingen ($p = 0.299$, na Holm 0.597) — en het verschil wijst niet eens de goede kant op. Structurele plasticiteit levert ook bij een omslag binnen één leven geen aantoonbare aanpassingssnelheid op. Daarmee strekt de conclusie van sectie 10.8 zich uit tot niet-stationaire omgevingen.

2. De herstructurering piekt niet na een omslag — en dit is de bevinding. Als plasticiteit ergens moet aanslaan, dan in de vijftig pogingen nadat de omgeving verandert. Gemeten wordt het tegendeel: het aantal herstructureringsgebeurtenissen per poging bij ANG gaat $2,25 \rightarrow 2,18$ rond poging 300 (5 van 12 zaden omhoog, $p = 0.774$) en $1,96 \rightarrow 1,84$ rond poging 600 (4 van 11 zaden omhoog, $p = 0.549$). Bij één conditie gaat de activiteit rond de tweede omslag zelfs aantoonbaar omlaag (ang-geensnoei, $p = 0.006$). De herstructurering loopt op een vaste klok en merkt niet dat de omgeving verandert. Dat is de nuttigste uitkomst van deze sectie, want zij verklaart alle andere: een mechanisme dat verbouwt op een klok kan per constructie niet reageren op een omslag die het niet waarneemt. De vraag is daarmee niet langer "levert structurele plasticiteit iets op?" maar "levert *deze* aansturing van structurele plasticiteit iets op?" — en dat is een vraag met een aanwijsbaar en herstelbaar antwoord.

3. Het vergeten zit niet in de plasticiteit, maar het zit er wel. ANG verliest tijdens de knipperfase 13.8 procentpunt van taak A, en de bevroren variant 12.7 procentpunt ($p = 0.840$): het verbouwen maakt het vergeten niet erger. Maar beide ANG-varianten verliezen ruim tien procentpunt, terwijl het geheugenloze vaste net er 0.7 procentpunt bij wint en het recurrente net 2.2 procentpunt verliest. De interferentie is dus een eigenschap van de leerregel en de graaf, niet van de structurele plasticiteit.

4. Het snoeien is vrijgesproken. De voor de hand liggende verdachte uit sectie 10.8 was het snoeien: dat gooit tijdens de moeilijke fase capaciteit weg die daarna terug moet groeien. Zonder snoeien herstelt het leven in 21.3 pogingen, tegen 26.8 pogingen mét snoeien ($p = 0.707$) — het verschil valt binnen de ruis. Het verlies zit niet in het snoeien.

5. De vaste netten herstellen sneller omdat zij niets kwijtraakten. Het vaste recurrente net herstelt in 1.5 pogingen tegen 26.8 voor ANG ($p < 0.001$, na Holm < 0.001), en dat getal betekent iets anders dan het lijkt. Datzelfde net haalt $64.0\% \pm 6.5$ tijdens de knipperfase zelf en $68.1\% \pm 1.6$ op taak A tijdens die fase: voor hem is de omslag geen verstoring. Hersteltijd meet daar de afwezigheid van een verstoring en niet de snelheid van aanpassing. Hetzelfde geldt in zwakkere vorm voor het geheugenloze net, dat de knipperfase niet kan maar er ook niets door verliest. Dat maakt de getallen niet ongeldig, maar het bepaalt wel wat je ermee mag beweren.

Eén ding moet erbij, en het werkt in het voordeel van ANG. Het plateau van de eerste fase is niet uitgeleerd: ANG staat daar na 300 pogingen op $56.9\% \pm 6.2$, terwijl sectie 10.8 na 500 pogingen op een hogere waarde uitkomt. De hersteldrempel ligt daardoor lager dan het uiteindelijke kunnen, en de derde fase profiteert van leren dat sowieso nog liep — zichtbaar in de positieve terugwinst. Dat werkt in het voordeel van ANG, en ANG wint er nog steeds niets mee; de negatieve conclusie van deze sectie is dus conservatief. Bij de vaste netten werkt het de andere kant op: die waren al uitgeleerd en zakken over het leven licht weg.

10.10 Structuur tegen gedrag, over alle metingen heen

Alle voorgaande secties meten één reeks tegelijk. Deze sectie doet iets anders: zij stelt vier vragen aan het materiaal dat er na de secties 10.7 tot en met 10.9 al ligt — 128 runs met bekende structurele ingrepen, 240 runs over een taakas, en zestig levens met twee omslagen — zonder ook maar één run opnieuw te draaien. Dat maakt deze sectie exploratief: de vragen zijn ná de metingen gesteld, niet ervoor, en er staan dan ook geen p-waarden bij de correlaties. Waar zij toe dient is iets anders dan bevestiging, namelijk de vraag of de structuurmaten van sectie 6 überhaupt iets over gedrag zeggen.

Correleert structuur met gedrag binnen één architectuur?

De correlatietabel aan het eind van sectie 10.8 loopt over vier architecturen tegelijk, en het voorbehoud daarbij was dat zij vooral meet welke architectuur een run is. Die tabel is hier herhaald binnen alleen de ang-runs van diezelfde as: 48 runs, één architectuur, alleen de taakstand verschilt. En omdat een correlatie over vier taakstanden precies hetzelfde euvel kan hebben — de stand beweegt zowel de structuur als de score mee — staat elke stand er ook afzonderlijk naast.

structuurmaat tegen benchmarkscore	gepooled	b 0	b 10	b 20	b 40
verbindingen	0.68	0.08	0.63	-0.05	0.48
actieve verbindingen	0.23	0.44	0.25	0.20	-0.09
neuronen	0.45	0.24	0.47	-0.16	0.34
reflexbogen	0.18	0.12	-0.26	-0.03	0.50
gesnoeid	-0.32	0.17	-0.16	-0.23	0.18
hertyperingen	0.41	-0.05	0.45	0.12	0.42

Het voorbehoud was terecht, en de omvang ervan is het vermelden waard. De sterkste gepoolde samenhang — het aantal verbindingen tegen de benchmarkscore, 0.68 — houdt binnen de afzonderlijke standen geen stand: daar loopt hij van -0.05 tot 0.63, en het teken wisselt. Een gepoolde correlatie over standen meet hier dus grotendeels dat een makkelijker stand zowel meer verbindingen als een hogere score oplevert, en niet dat meer verbindingen iets voorspellen. Dat is dezelfde fout als de architectuurfout uit sectie 10.8, één niveau lager, en zij is precies daarom hier opgeschreven: het is de fout die dit type tabel vanzelf maakt als niemand hem uitsplitst.

Vier structuurmaten hebben geen variatie om mee te correleren. Over alle 48 runs heen — twaalf breinzaden, vier taakstanden — zijn kortste pad, lussen, geheugen-neuronen en bijgegroeid in elke run identiek. Dat is geen meetfout maar een eigenschap van het model: deze maten liggen vast aan de

architectuur en de startconfiguratie, niet aan de taak en niet aan het toeval van het zaad. Voor sectie 6 betekent dat iets ongemakkelijks. Een structuurmaat die onder geen enkele omgevingsdruk beweegt, kan geen verklaring zijn voor gedrag dat wél beweegt.

Wat stabiliseert er eerst, de structuur of het gedrag?

De levens van sectie 10.9 leggen per poging vast hoe groot het netwerk is en hoe goed het speelt. Daarmee is te bepalen wat er eerder tot rust komt. Per blok van 25 pogingen wordt het laatste blok bepaald waarna de blok-op-blok-verandering nooit meer boven een tiende van de grootste sprong in dat leven komt — voor de netwerk grootte en voor het succes afzonderlijk, en per zaad gepaard vergeleken.

conditie	structuur komt tot rust op blok	gedrag op blok	verschil	zaden
ANG	30.9	35.0	-4.1	12 van 12 negatief, $p < 0.001$
ANG, structuur bevroren	0.0	34.9	-34.9	12 van 12 negatief, $p < 0.001$
ANG zonder snoeien	35.0	35.0	0.0	geen verschil

Eerst hoe deze tabel gelezen moet worden. Een leven telt 36 blokken, genummerd 0 tot en met 35. Een waarde van 35 betekent dus niet "hier kwam het tot rust" maar "binnen dit leven is het niet tot rust gekomen". Het gedrag haalt die rand in elke conditie, en dat is te verwachten: geen van de drie fasen van driehonderd pogingen is uitgeleerd, zoals sectie 10.9 al meldt. De absolute settelwaarde van het gedrag zegt daarom weinig; het *verschil* tussen structuur en gedrag zegt wél iets, en dat verschil is per zaad gepaard.

De structuur komt eerder tot rust dan het gedrag, in elk leven. Bij ANG settelt de netwerk grootte gemiddeld 4.1 blokken — ongeveer 100 pogingen — vóór het succes dat doet, en dat geldt voor alle twaalf zaden afzonderlijk ($p < 0.001$). De richting is daarmee eenduidig: het verbouwen is klaar terwijl het leren doorgaat. De bevroren variant levert de controle dat de maat doet wat hij zegt — daar is geen sprong om te settelen, en de maat geeft dan ook blok nul.

Zonder snoeien komt de structuur helemaal niet tot rust. Bij de conditie zonder snoeien groeit het aantal verbindingen het hele leven vrijwel monotoon door en bereikt binnen 900 pogingen geen vast punt; de maat loopt daar tegen de rand van het meetvenster aan en is dus niet zinvol te vergelijken. Dat is zelf het resultaat: snoeien is wat een groeiende graaf een stabiele grootte geeft. Sectie 10.9 sprak het snoeien vrij van het herstelprobleem; deze waarneming geeft het meteen een functie terug die het wél heeft.

Komen twaalf beginwolken op dezelfde organisatie uit?

De twaalf eindnetwerken van de ang-levens uit sectie 10.9 verschillen alleen in hun breinzaad: dezelfde regels, dezelfde omgeving, een ander toeval bij de start. De vraag is of zij op vergelijkbare functionele organisaties uitkomen, of op verschillende oplossingen met dezelfde score. Per netwerk is daarvoor het aandeel van elke neuronsoort genomen samen met de verdeling van de verbindingen over de soortenparen.

soort	aandeel van de verborgen neuronen
zintuig	0.068 ± 0.011
werker	0.820 ± 0.016
reflex	0.040 ± 0.013
geheugen	0.071 ± 0.000
neutraal	0.000 ± 0.000

De twaalf komen op een smalle band uit, en de score hangt er nauwelijks mee samen. Over de 66 paren zaden correleert de onderlinge organisatie-afstand met het verschil in eindscore met $\rho = 0.15$. Twee netwerken die organisatorisch verder uit elkaar liggen presteren dus nauwelijks verschillender dan twee die dicht bij elkaar liggen. Dat is eerder het beeld van lichte variatie rond één organisatie dan van werkelijk verschillende oplossingen: het aandeel geheugen-neuronen is over alle twaalf zaden zelfs exact gelijk. Voor de vraag waar dit werk uit voortkomt is dat een bruikbaar negatief resultaat — de bedradingsgrammatica laat kennelijk maar weinig speelruimte, en wat er aan structuur ontstaat is meer voorgeschreven dan gevonden.

Waar reageert de herstructurering dan wél op?

Sectie 10.9 stelt vast dat de herstructurering niet reageert op de twee omslagen. Dat laat open waar zij dan wél op reageert. De configuratie belooft iets concreets: herstructureren gebeurt elke tien pogingen, en dan nog alleen bij stagnatie. Dat is hier fijnmaziger getoetst, met de verandering van het succes over de tien voorgaande pogingen als stagnatiesignaal, op elke klokslag van elk leven met plasticiteit.

- **De stagnatievoorwaarde filtert niets.** Op 100.0 % van alle klokslagen gebeurt er iets. Als poort is de voorwaarde dus zo goed als altijd open, en in dat opzicht gedraagt het mechanisme zich inderdaad als een klok.
- **Maar de hoeveelheid herstructurering hangt er wél mee samen.** Op klokslagen waar het succes daalt of vlak ligt vinden gemiddeld 3.9 gebeurtenissen meer plaats dan op klokslagen waar het stijgt, en dat geldt in 24 van de 24 levens dezelfde kant op ($p < 0.001$). De rangcorrelatie tussen churn en die trend is gemiddeld -0.32.
- **En dat is geen tijdsdrift.** Churn neemt over een leven geleidelijk af ($\rho = -0.40$ met het pogingnummer), dus het verband met de trend zou een gedeeld verloop met de tijd kunnen zijn. Binnen elke fase afzonderlijk — een venster van driehonderd pogingen — blijft het echter staan: -0.38, -0.34, -0.23 voor de drie fasen.

Dat maakt de bevinding van sectie 10.9 scherper in plaats van onwaar. Het mechanisme is niet blind: het verbouwt meer wanneer het leren vastloopt, precies zoals de configuratie belooft. Maar gevoeligheid voor stagnatie is niet hetzelfde als gevoeligheid voor een omslag. Een omslag hoeft geen aanhoudende stagnatie te veroorzaken — de agent kan meteen op een lager niveau verder leren, en dat is in de knipperfase precies wat er gebeurt — en omgekeerd treedt stagnatie ook op zonder dat er iets aan de omgeving verandert. Het signaal waarop dit mechanisme stuurt staat dus loodrecht op het signaal dat het zou moeten opmerken. Dat is een preciezere diagnose dan "het loopt op een klok", en zij wijst een concretere reparatie aan.

Met één voorbehoud dat hier hoort te staan. Het stagnatiesignaal is afgeleid uit het gedrag van de agent zelf en niet uit de omgeving. De samenhang is daarmee deels circulair te lezen: minder herstructurering omdat het netwerk al goed genoeg speelt, in plaats van meer herstructurering omdat het vastzit. Die twee zijn met deze gegevens niet uit elkaar te trekken, en dat is precies de reden dat de vervolgmeting in sectie 10.11 een signaal nodig heeft dat los van het eigen gedrag van het netwerk staat — en dat daar dan ook op de invoerstatistiek gebouwd is.

10.11 Herstructurering op een omgevingssignaal

Secties 10.9 en 10.10 wijzen samen een oorzaak aan: de herstructurering wordt aangestuurd door een vaste klok, en waar zij op een signaal reageert is dat de stagnatie van het eigen leren en niet een verandering in de omgeving. Een aangewezen oorzaak is geen getoetste oorzaak. Deze sectie vervangt de klok door een detector op de omgeving en draait de omslagproef van sectie 10.9 verder onveranderd opnieuw: dezelfde fasen, dezelfde 12 breinzaden, dezelfde herstelregel, dezelfde meetpunten. Alleen de aansturing van de poort verschilt, want dat is de vraag.

Wat de detector meet, en waarom niet de beloning

De detector kijkt uitsluitend naar de invoer. Per poging wordt van elk van de zestien invoerkanalen het gemiddelde over de spelstappen genomen; daar lopen een snel en een traag exponentieel gemiddelde overheen (20 en 150 pogingen). Het verschil daartussen wordt per kanaal gedeeld door zijn eigen standaardfout en kwadratisch samengenomen, zodat het resultaat een z-maat is die onder een stilstaande omgeving rond één ligt. De poort vuurt wanneer die maat boven mediaan plus $3 \times \text{MAD}$ van haar eigen recente verloop uitkomt — een meelopende drempel, zodat er geen getal met de hand gekozen hoeft te worden.

Het signaal mag niet uit het gedrag van het netwerk komen. Sectie 10.10 eindigt met dat voorbehoud en het is hier bindend. Een poort die op de lopende beloningsbasislijn stuur, meet precies de samenhang die daar al gerapporteerd is, en die is circulair te lezen: minder verbouwen omdat het netwerk al goed speelt is dan niet te onderscheiden van meer verbouwen omdat het vastzit. De invoerstatistiek heeft dat bezwaar niet — zij verschuift bij een omslag ongeacht hoe goed de agent speelt.

De instellingen van de detector zijn gekalibreerd op de klokconditie. Daar loopt de detector mee zonder iets te sturen, dus er was geen uitkomstmaat om op te kiezen; gemeten is alleen of de poort in een stilstaande fase stil blijft en bij een omslag aanslaat. Dat de nieuwe knop in haar uitstand werkelijk niets doet, is niet aangenomen maar nagerekend: de klokconditie levert met hetzelfde zaad bit voor bit hetzelfde leven op als de ang-conditie van sectie 10.9 — historie, netwerk en herstructureringen identiek.

Vuurt de poort waar zij zou moeten vuren?

Dit is een controle op de ingreep en geen uitkomstmaat: voordat er iets over herstel gezegd mag worden, moet vaststaan dat de poort werkelijk op de omgeving reageert. De vuurkans binnen vijftig pogingen na een omslag staat daarom naast die in de rest van het leven, per omslag afzonderlijk en per zaad gepaard. Elke poging heeft een eindige, niet-negatieve waarde en elke drempel is eindig zodra de detector rijp is; die controle gaat vooraf aan elke vergelijking, omdat een meting eerst moet bewijzen dát er gemeten is.

omslag	vuurkans elders	vuurkans binnen 50 pogingen	zaden omhoog	eerste keer vuren
300 (naar knippen)	$4.2\% \pm 1.8$	$0.2\% \pm 0.3$	0 van 12, $p < 0.001$	1 van de 12 levens, na 50.0 ± 0.0 pogingen
600 (terug naar zichtbaar)	$4.2\% \pm 1.8$	$56.0\% \pm 9.6$	12 van 12, $p < 0.001$	alle 12 levens, na 3.2 ± 0.4 pogingen

Bij de terugslag naar de oorspronkelijke taak doet de poort precies wat zij moet doen. De vuurkans gaat van $4.2\% \pm 1.8$ naar $56.0\% \pm 9.6$, in 12 van de 12 levens dezelfde kant op ($p < 0.001$), en zij slaat gemiddeld 3.2 ± 0.4 pogingen na de omslag voor het eerst aan. De onderliggende maat gaat daarbij van 1.44 naar 1.94.

Bij de omslag naar het knipperende doel mist de detector hem, en dat hoort er onverkort bij te staan. Daar gaat de vuurkans van $4.2\% \pm 1.8$ naar $0.2\% \pm 0.3$, en in 11 van de 12 levens vuurt de poort binnen het venster in het geheel niet. De maat zelf beweegt wel de goede kant op — van 1.44 naar 1.70 — maar niet ver genoeg boven de meelopende drempel. De reden is te zien in de ruwe kanaalgemiddelden: wanneer het doel verdwijnt zakken de doelkanalen naar nul, en nul is een waarde die zij in de zichtbare fase ook geregeld aannemen, zodat de verschuiving klein is ten opzichte van de spreiding die er toch al was. Komt het doel terug, dan springen diezelfde kanalen omhoog uit een fase waarin zij nauwelijks varieerden, en dat is een veel grotere verschuiving in spreidingseenheden. Voor de vraag van deze sectie is dat draaglijk: het herstel wordt gemeten ná de terugslag, en dáár vuurt de poort. Maar de detector is daarmee geen algemene omslagdetector, en zo wordt hij hier ook niet gepresenteerd.

Leverf verbouwen op het juiste moment herstel op?

De vier condities verschillen alleen in de aansturing van de poort. De budgetconditie is er omdat een signaalgestuurde poort niet alleen op andere momenten verbouwt maar ook een ander aantal keren: haar klokperiode is per zaad zó gezet dat zij evenveel herstructureringsronden haalt als het signaallevens van datzelfde zaad. Zonder die controle zou een verschil in herstel even goed aan de hoeveelheid als aan het moment kunnen liggen.

aansturing	ronden per leven	ronden binnen 50 pogingen na de terugslag	hersteltijd (pogingen)	behoud (pp)
klok (als sectie 10.9)	90.0 ± 0.0	5.0 ± 0.0	26.8 ± 8.4	-13.8 ± 9.5
omgevingssignaal	55.4 ± 15.4	28.0 ± 4.8	30.3 ± 8.4	-11.9 ± 3.8
klok, zelfde hoeveelheid als het signaal	55.3 ± 15.6	3.0 ± 0.9	29.4 ± 7.6	-15.4 ± 5.5
structuur bevroren	0.0 ± 0.0	0.0 ± 0.0	32.4 ± 7.9	-12.7 ± 3.5

De ingreep doet wat zij moet doen aan de verdeling van het verbouwen. Het signaallevens legt 28.0 ± 4.8 van zijn 55.4 ± 15.4 rondens in de vijftig pogingen na de terugslag; de budgetconditie, met hetzelfde aantal rondens over het hele leven, komt daar op 3.0 ± 0.9 en de gewone klok op 5.0 ± 0.0 . Het verschil tussen de condities zit dus werkelijk in het moment en niet in de hoeveelheid, en de koppeling per zaad wijkt nergens meer dan één ronde af.

En het levert geen herstelvoordeel op. De hersteltijd is 30.3 ± 8.4 pogingen tegen 26.8 ± 8.4 voor de klok, en dat verschil blijft binnen de meetruis ($p = 0.453$, Holm 1.000). Tegen de bevroren structuur, die 32.4 ± 7.9 pogingen nodig heeft, is het beeld hetzelfde ($p = 0.840$, Holm 1.000). Ook tegen de budgetconditie verschuift er niets ($p = 0.707$, Holm 1.000). Geen van de 48 levens is gecensureerd: elke conditie haalt haar oude plateau binnen de derde fase terug.

Het moment weegt niet zwaarder dan de hoeveelheid. Beschrijvend, met alle drie de gemiddelden naast elkaar: het verschil tussen signaal en budget — gelijke hoeveelheid, ander moment — is 0.9 pogingen, en dat tussen budget en de gewone klok — zelfde soort aansturing, andere hoeveelheid — 2.7 pogingen. Beide liggen ruim binnen de intervallen van de afzonderlijke gemiddelden, die alle drie ongeveer acht pogingen breed zijn. Uit deze meting valt dus niet af te leiden dat het moment van verbouwen ertoe doet, en evenmin dat de hoeveelheid ertoe doet.

Gericht verbouwen kost ook geen extra behoud. De score op taak A verandert over de knipperfase met -11.9 ± 3.8 procentpunt tegen -13.8 ± 9.5 voor de klok ($p = 0.795$, Holm 1.000). Het stabiliteit-plasticiteitsruilpunt dat sectie 10.9 niet kon aantonen, wordt hier dus ook niet zichtbaar wanneer de plasticiteit gericht wordt.

Wat wél opvalt, staat in de eindstanden en niet in de hersteltijd. Op de benchmark aan het eind van het leven staat de signaalconditie op $67.6\% \pm 1.9$, de budgetconditie op $65.6\% \pm 4.5$, de gewone klok op $64.1\% \pm 3.0$ en de bevroren structuur op $68.5\% \pm 2.4$. De twee condities die minder verbouwen — ongeveer 55 ± 15 rondens tegen 90 ± 0 — liggen daarmee dicht bij de bevroren variant dan de gewone klok, en de bevroren variant staat bovenaan. Die intervallen overlappen en dit is geen voorgeregistreerde vergelijking, dus er hangt geen conclusie aan; het past wel bij wat sectie 10.8 al vond, namelijk dat herstructureren op deze taakfamilie eerder een kostenpost dan een opbrengst is.

Wat deze sectie aan het betoog verandert. Sectie 10.9 vond geen herstelvoordeel en wees een oorzaak aan; sectie 10.10 maakte die aanwijzing preciezer maar bleef een correlatie. Hier is de aangewezen oorzaak weggenomen — de herstructurering ziet de terugslag nu binnen een handvol pogingen en verbouwt daar 17 keer zo dicht als in de rest van het leven — en het herstel verandert er niet van. Daarmee is de negatieve bevinding van sectie 10.9 niet langer aan die ene ontwerpkeuze toe te schrijven. Dat is een ongemakkelijker uitkomst dan de omgekeerde zou zijn geweest, en een

sterkere: de conclusie van dit werk rust vanaf hier op een getoetste oorzaak in plaats van op een aangewezen correlatie.

Met twee voorbehouden. Het eerste is de detector: hij ziet de terugslag naar de zichtbare taak wel en de overgang naar het knipperende doel niet, dus deze meting toetst de aansturing bij één van de twee omslagen en niet bij beide. Het tweede is de maat. De hersteltijden van de vier aansturingen liggen alle tussen 27 en 32 pogingen, en geen enkel leven is gecensureerd, zodat er weinig ruimte is waarin een voordeel zichtbaar zou kunnen worden. Een omslag die dieper snijdt of een plateau dat hoger ligt zou die ruimte vergroten; beide zouden een nieuwe meetreeks vergen en geen van beide is hier gedaan.

10.12 Hoe groot moet het netwerk zijn?

Dit is de vraag waar dit onderzoek uit voortkomt, en zij heeft tot hier moeten wachten. Een capaciteitsvraag is pas zinvol op een taak waar capaciteit werkelijk knelt, en zolang het doel altijd zichtbaar was, knelde er niets. Sinds sectie 10.8 bestaat die taak wel. Gemeten is een raster van 5 netwerkgroottes (8, 16, 30, 60, 120 neuronen) tegen 3 startdichtheden (15, 35, 70), op twee taakstanden, met 8 zaden per cel en een leersnelheid die per grootte en per stand apart is geveegd op eigen zaden.

De soortenverdeling schaalt mee met de grootte en wordt niet gevarieerd. De grenzen per neuronsoort zijn absolute aantallen, afgesteld op zestig neuronen. Laat je ze staan terwijl je naar acht zakt, dan wringt de samenstelling zichzelf plat tegen de ondergrenzen en varieert er naast de grootte ook de verhouding tussen de soorten. De grenzen schalen daarom evenredig mee, zó gekozen dat zij bij zestig neuronen exact de bestaande waarden teruggeven. De vraag van deze sectie is hoévél neuronen, niet welke.

De grootte-as wordt per grootte op de beste dichtheid gelezen. Bij de grote netwerken is de laagste dichtheid rampzalig — honderdtwintig neuronen halen daar minder dan acht neuronen op hun beste bedrading. Middel je die cel mee, dan meet de grootte-as voor een derde hoe erg te dun bedraad zijn is, en dat is de vraag van de andere as. In beide tabellen hieronder staat daarom per grootte de beste van de drie dichtheden, met die dichtheid erbij vermeld.

taak A, doel altijd zichtbaar

neuronen	beste dichtheid	benchmark	geheugenhorizon	losgeraakte neuronen	sd tussen zaden
8	15	26.5% ± 11.5	7.8	30.5	16.7 pp
16	35	54.1% ± 4.0	7.3	41.0	5.8 pp
30	35	58.3% ± 6.0	13.1	10.0	8.6 pp
60	70	68.5% ± 4.4	18.1	2.6	6.3 pp
120	70	67.8% ± 1.3	18.9	6.6	1.9 pp

Het optimum ligt binnen het raster. De hoogste score staat bij 60 neuronen. Vanaf daar kost verder vergroten 0.7 procentpunt en verkleinen tot de kleinste maat 42.0 procentpunt.

taak B-20, tien stappen zicht en twintig donker

neuronen	beste dichtheid	benchmark	geheugenhorizon	losgeraakte neuronen	sd tussen zaden
8	15	5.4% ± 2.5	2.8	0.8	3.6 pp
16	15	8.8% ± 1.9	2.0	1.8	2.7 pp
30	35	10.4% ± 2.3	6.3	1.5	3.3 pp
60	70	14.0% ± 2.9	11.6	3.4	4.2 pp

neuronen	beste dichtheid	benchmark	geheugenhorizon	losgeraakte neuronen	sd tussen zaden
120	70	18.5% $\pm$ 7.3	14.9	6.8	10.5 pp

Het optimum ligt hier op de rand van het raster, en dan is het geen optimum. De hoogste score staat bij 120 neuronen. Dat is de buitenste maat die gemeten is, dus wat deze stand laat zien is niet "hier ligt het optimum" maar "tot aan 120 neuronen blijft meer beter". Die uitspraak is zwakker dan de vraag vroeg, en zij hoort zo te staan; het raster moet verder worden doorgetrokken voordat er iets over een optimum wordt beweerd.

Waaraan je het ziet, en waaraan niet

Een score zegt dát het misgaat en niet waaraan je het had kunnen zien. De praktische vraag is of er aan één getraind netwerk af te lezen valt dat het verkeerd gedimensioneerd is, zonder een tweede netwerk te trainen om mee te vergelijken. Daarvoor staan hieronder zes maten die alle al sinds sectie 6 bestaan en nog nooit een taak hadden waarop zij iets konden betekenen, elk tegen de benchmarkscore van hun cel.

maat	rho met de score, A	rho met de score, B20
geheugenhorizon (functioneel)	0.78	0.70
actieve verbindingen	0.61	0.75
verbindingen totaal	0.60	0.65
meedoende neuronen	0.44	0.62
gemiddeld gewicht t.o.v. het plafond	0.53	0.48
losgeraakte neuronen	-0.62	0.21

De maat die het op beide standen volhoudt, is de enige functionele van het stel. Beoordeeld op het zwakste van de twee getallen — want een diagnose die maar op één taak werkt is er geen — komt de geheugenhorizon uit de blinderingsproef bovenaan met 0.78 en 0.70, gevolgd door het aantal actieve verbindingen met 0.61 en 0.75. Het is de enige maat in het rijtje die niet telt wat er gebouwd is maar meet wat het netwerk kán, en dat maakt de uitkomst meer dan een rangorde: het is dezelfde boodschap als sectie 10.8, nu niet als methodologisch standpunt maar als meetresultaat. Op B20 wordt hij afzonderlijk voorbijgestreefd door een structurele telling, dus de winst zit in consistentie en niet in afstand. Onderaan staat het aantal losgeraakte neuronen, en niet omdat het laag scoort maar omdat het van teken wisselt tussen de twee standen (-0.62 tegen 0.21). Een maat die van richting verandert zodra de taak verandert, is als losse diagnose onbruikbaar — hij zou een te groot netwerk op de ene taak gezond noemen en op de andere ziek.

Eén voorgeregistreerde verwachting is onderuitgegaan, en het is de moeite waard te zeggen waarom. Vooraf stond opgeschreven dat een te klein netwerk zijn gewichten tegen het plafond zou duwen. Dat gebeurt niet: het gemiddelde gewicht komt in geen enkele cel boven een twintigste van het plafond uit, en de samenhang met de grootte is positief in plaats van negatief — grotere netwerken hebben gemiddeld zwaardere gewichten, geen kleinere. De maat heet in de meetbestanden nog "randdruk", en die naam belooft meer dan hij waarmaakt; wat hij meet is gemiddelde gewichtsgrootte, en verzadiging tegen het plafond komt in dit model bij geen enkele grootte voor.

De dichtheidsknop heeft een plafond dat met de grootte meeschuift

Tijdens het draaien bleek iets wat niet was voorzien en wat op zichzelf een antwoord is. Bij kleine netwerken leveren twee verschillende startdichtheden exact hetzelfde netwerk op. De reden staat in de constructie: het aantal verbindingen is het minimum van het aantal legale paren en dichtheid maal netwerk-grootte, en bij weinig neuronen loopt die eerste term het eerst vol. Boven dat plafond doet de knop niets meer.

neuronen	dichtheid 15	dichtheid 35	dichtheid 70	plafond bereikt vanaf
8	902	902	902	dichtheid 35
16	1172	1157	1157	dichtheid 70
30	1303	1757	1757	dichtheid 70
60	1795	3075	3926	niet binnen dit raster
120	2083	4331	8114	niet binnen dit raster

Wat dat praktisch betekent. Onder ongeveer dertig neuronen is de bedradingsdichtheid geen instelbare knop meer maar een gevolg van de grootte: er zijn simpelweg niet genoeg toegestane verbindingen om er meer te maken. Wie een klein netwerk dichter wil bedraden, moet het groter maken of de bedradingsgrammatica verruimen — de schuif verzetten doet niets. Dat is geen meetfout maar een eigenschap van het model, en het verklaart waarom de dichtheid in de eerdere secties zo weinig varieerde: die draaiden alle op zestig neuronen, net boven de plek waar de knop weer begint te werken.

Van de twee knoppen is de grootte de sterkste, maar niet met grote voorsprong. Binnen een grootte spant de dichtheid 23.5 en 5.2 procentpunt; binnen een dichtheid spant de grootte 37.9 en 7.2 procentpunt. De hint in de testpagina die de startdichtheid "veruit de belangrijkste knop" noemt, stamt van vóór de structurele plasticiteit en is daarmee achterhaald — maar alleen in de rangorde. Een knop die tientallen procentpunten waard is, blijft een knop die je goed moet zetten, en op de grote netwerken is te dun bedraden nog steeds de duurste fout die er in dit raster te maken valt.

Het antwoord op de vraag waar dit werk uit voortkomt, zo scherp als deze meting hem toelaat. Te klein is veel duurder dan te groot. Op beide standen kost terugschalen naar de kleinste maat tientallen procentpunten en kost doorschalen naar de grootste vrijwel niets. De gangbare vuistregel — neem hem ruim — is op deze taakfamilie dus gewoon juist, en de tegengestelde verwachting die vooraf was opgeschreven is onderuitgegaan. Hoevéél ruim hangt van de taak af: zonder geheugendruk ligt het optimum bij 60 neuronen, met geheugendruk is er binnen dit raster geen optimum gevonden. En herkennen doe je een verkeerd gedimensioneerd netwerk aan de maat die hierboven als enige op beide standen overeind bleef; welke dat is, staat daar en wordt hier niet nog een keer met de hand opgeschreven.

10.13 Een tweede taak: het seinhuis

Alles hierboven is gemeten op één spel met één tijdschaal, één soort antwoord en een vaste hoeveelheid werk. De vorige versie van dit document noemde een tweede taak als de meest voor de hand liggende verklaring voor de reeks negatieve bevindingen: een netwerk dat zijn structuur kan verbouwen heeft op het eerste spel per constructie weinig te verbouwen. Deze sectie beschrijft die tweede taak, wat de kalibratie ervan opleverde, en waarom zij is afgesloten voordat de meting waarvoor zij gebouwd was, kon beginnen.

De taak. Geen ruimte en geen navigatie: een stroom van acht seinlampen, een wisselstand en zeven afleiderkanalen, en vier handels. Zes regels, elk één zin: lamp 0 bij open wissel vraagt handel 0 en lamp 1 bij gesloten wissel handel 1, deze tik; lamp 3 vraagt handel 0 als er sinds de vorige lamp 3 een lamp 2 was en anders handel 1 (vijf tot vijftien tikken ertussen); lamp 5 idem met lamp 4 en handel 2 of 3 (dertig tot zeventig tikken); elke derde lamp 6 vraagt handel 2; lamp 7 twee keer binnen drie tikken vraagt handel 3. Elke handel wordt door twee regels gebruikt, zodat een handel nooit verraadt om welke regel het gaat. Een dienst duurt 240 tikken.

De score, en twee keer dat hij niet deugde

Elke regel is een onderscheid tussen twee soorten gevallen: lamp 0 bij open tegen gesloten wissel, lamp 3 met tegen zonder voorafgaande lamp 2, de derde lamp 6 tegen de andere. De eerste versie scoorde

alleen de gevallen waarin een handel gevraagd werd, en een geheugenloos net dat bij elke lamp de bijbehorende handel indrukte haalde daarmee boven de negentig procent op een regel die over tellen gaat. De tweede versie nam het meetkundig gemiddelde van de trefkans aan beide kanten; daarmee kwamen altijd-reageren en nooit-reageren op nul, maar een geheugenloos net dat bij lamp 3 willekeurig tussen handel 0 en 1 koos, haalde 51 procent zonder iets van de vlag te weten. De score is nu Youdens J: trefkans aan de ene kant plus trefkans aan de andere kant min één. Nul betekent dat de reactie niet afhangt van wat de regel zegt dat ertoe doet — en dat geldt voor altijd, nooit én een munt. Eén is perfect. De controletest meet die schaal na met zes gescripte spelers, waaronder de twee die de eerdere versies doorlieten.

De methodologische les is algemener dan dit spel. Beide fouten werden niet gevonden door een toevalsbodem maar door een speler die precies één stap slimmer was dan de vorige: eerst "lamp aan, handel erbij", toen "gooi een munt tussen de twee goede antwoorden". Een score hoort getoetst te worden tegen de beste strategie die het bedoelde vermogen níét heeft, en niet alleen tegen toeval.

De kalibratie

Vóór de basislijnen is per architectuur één proefleven gedraaid, op zaden buiten de meetzaden. Dat leverde vier bevindingen op die de opzet van de afsluitende meting bepaalden. Met de oorspronkelijke beloning stortte elk net — ook een backpropnet dat de eerste regel los binnen duizend diensten leert — binnen driehonderd diensten in naar "nooit drukken": vier onafhankelijke handels die met REINFORCE geleerd worden verzadigen naar nooit of altijd, en daar is de gradiënt nul. Eén keuze per tik — niets, of precies één handel — hielp niet. De eerste regel stierf zolang de achtergrond werd afgestraft, omdat zijn voorwaarde (open wissel) op de helft van alle stille tikken ook waar is. En geen enkel net leerde een regel die geheugen vraagt.

Correctie op sectie 10.8 en 10.9. Het recurrente vergelijkingsnet dat daar als "backprop door de tijd" stond beschreven, propageert niet terug door de tijd. De exacte gradiënt loopt alleen over voorwaartse bogen, en een terugkoppelende boog krijgt de toestand van de vorige tik als presynaptische waarde; het spoor rekt dat tot twee à drie tikken. De labels in die secties zijn aangepast. Op het eerste spel verandert dat aan geen enkele conclusie iets — koers houden is continuïteit en geen opgeslagen bit — maar het betekent wel dat de sterkste tegenstander in dit document tot hier geen echt geheugen kon leren. Voor deze sectie is daarom een Elman-net gebouwd met terugpropagatie door de hele dienst: dezelfde schatter, hetzelfde spoor, dezelfde basislijn en rem, met de gradiënt door alle 240 tikken terug en een update per dienst. Een controle met eindige differenties over alle gewichten geeft een cosinus van 1,000000.

De afsluitende meting

Om de negatieve uitkomst niet op één zaad te laten rusten, is de gunstigste opzet uit de kalibratie één keer volledig gemeten: een groeiende dienstregeling (1000 diensten per regel, regels die blijven), één keuze per tik, een beloning die de achtergrond niet afstraft, een leersnelheid per conditie geveegd op eigen zaden, en 12 zaden per conditie met elk een eigen brein- en wereldzaad. De voorspellingen stonden vast voordat de eerste run draaide. De tabel geeft J per regel aan het eind van het leven, op 200 vaste diensten, in procenten, met het interval over de zaden.

conditie	η	R1	R2	R3	R4	R5	R6	totaal
ANG, met structurele plasticiteit	0.032	-5 ± 0	-5 ± 0	-95 ± 0	-95 ± 0	-7 ± 0	-7 ± 0	-36 ± 0
ANG, structuur bevroren	0.032	-3 ± 0	-2 ± 0	-97 ± 0	-97 ± 0	-3 ± 0	-3 ± 0	-34 ± 0
MLP-32, backprop (geen geheugen)	0.016	75 ± 1	91 ± 1	-3 ± 0	-3 ± 1	-2 ± 0	-1 ± 1	26 ± 0
Elman-32, backprop afgekapt op één tik	0.032	55 ± 19	65 ± 23	-18 ± 22	-34 ± 27	-2 ± 1	21 ± 12	15 ± 14

conditie	η	R1	R2	R3	R4	R5	R6	totaal
Elman-32, backprop door de hele dienst	0.016	65 ± 23	68 ± 27	-12 ± 16	-29 ± 25	-1 ± 1	0 ± 13	15 ± 13
Elman-64, backprop door de hele dienst	0.004	25 ± 22	17 ± 32	-18 ± 17	-47 ± 27	-19 ± 19	-1 ± 28	-7 ± 20

Geen enkel net leert een regel die geheugen vraagt. Van de 24 combinaties van conditie en geheugenregel ligt er na Holm geen enkele boven nul; de kleinste gecorrigeerde p is 0.188. Dat geldt ook voor het Elman-net met terugpropagatie door de hele dienst, en ook voor de brede variant daarvan. Wat R3 tot en met R6 vragen — een vlag vijf tot zeventig tikken vasthouden, tellen tot drie, twee lampen binnen drie tikken herkennen — ligt met REINFORCE en deze netten in dit budget buiten bereik, voor elke architectuur in dit document.

De regels zonder geheugen. R1 en R2 — één tik, alleen een voorwaarde op de wissel — worden betrouwbaar geleerd (ondergrens van het interval op het gemiddelde van beide boven 0,5) door: MLP-32, backprop (geen geheugen). Niet betrouwbaar: ANG, met structurele plasticiteit; ANG, structuur bevroren; Elman-32, backprop afgekapt op één tik; Elman-32, backprop door de hele dienst; Elman-64, backprop door de hele dienst. Het falen op de overige regels ligt dus aan het geheugen en niet aan de beloning of het beleid.

ANG leert zelfs de regels zonder geheugen niet. Op het gemiddelde van R1 en R2 haalt de vrije graaf $J = -5 \%$, het geheugenloze MLP 83 % (Holm $p < 0,001$) en dezelfde graaf bevroren -2% (Holm $p < 0,001$). Beide varianten van ANG zijn over de hele linie stil gebleven — al in de eerste fase, waarin alleen R1 bestaat, komt het onderscheid niet van nul. Het verschil tussen vrij en bevroren is significant maar klein, en valt in de richting die de eerdere secties steeds vonden: bevroren is niet slechter. Een beperking hoort hier direct bij: voor beide ANG-varianten koos de leersnelheidsveeg de hoogste van de drie kandidaten, en een keuze op de rand van het raster is geen optimum. Dat de score met de leersnelheid steeg (van ongeveer -58 naar -35%) maar in geen enkele variant boven nul kwam, maakt het onwaarschijnlijk maar niet uitgesloten dat een nog hogere waarde ANG over de drempel had geholpen. Hetzelfde geldt voor het Elman-net dat één tik terugleert.

De recurrente netten leren R1 in het ene zaad wel en in het andere helemaal niet. Elman-32, backprop afgekapt op één tik: 3 van de 12 zaden boven 80 %, 3 onder 10 %; Elman-32, backprop door de hele dienst: 7 van de 12 zaden boven 80 %, 3 onder 10 %; Elman-64, backprop door de hele dienst: 1 van de 12 zaden boven 80 %, 6 onder 10 %. Het geheugenloze MLP haalt in elk zaad ongeveer hetzelfde. Het gemiddelde met zijn brede interval verbergt dus geen middelmatig net maar twee soorten netten: een dat de regel beheerst en een dat is ingestort. Terugkoppeling maakt het leren hier niet sterker maar grilliger.

Eén aanwijzing die de correctie niet overleeft. Elman-32, backprop afgekapt op één tik haalt op R6 $J = 21 \pm 12$ (ongecorrigeerd $p = 0.008$, na Holm 0.19). R6 is de geheugenregel met de kortste tijdschaal — twee lampen binnen drie tikken — en daarmee de enige die binnen het bereik van een spoor van twee à drie tikken ligt. Het is juist niet het net met terugpropagatie door de hele dienst dat hier boven komt drijven. Na correctie is het geen bevinding, en het staat hier alleen omdat het in de richting wijst die de verklaring voorspelt.

Hoe een net faalt, niet alleen dát

Omdat elke regel twee kanten heeft, is per regel af te lezen wélke strategie een net gekozen heeft. "Stil" betekent nooit reageren (de ene kant bijna nul, de andere bijna één), "reflex" altijd reageren en de voorwaarde negeren, "munt" gokken tussen de twee antwoorden, "geleerd" een J boven de helft. Twee categorieën zijn na de meting toegevoegd, omdat de vooraf vastgelegde indeling ze onder "gemengd" schoof: bij R3 en R4 vragen beide kanten een handel, zodat nooit reageren daar "niets goed" oplevert en steeds hetzelfde antwoord "vast antwoord". Alle faalvormen halen J rond nul of lager — en ze zijn aan een gewone trefkans niet van elkaar, en de reflex en de munt niet van begrip, te onderscheiden.

conditie	R1	R2	R3	R4	R5	R6
ANG, met structurele plasticiteit	stil	stil	niets goed	niets goed	stil	stil
ANG, structuur bevroren	stil	stil	niets goed	niets goed	stil	stil
MLP-32, backprop (geen geheugen)	geleerd	geleerd	munt	vast antwoord	stil	stil
Elman-32, backprop afgekapt op één tik	geleerd	geleerd	munt	gemengd	stil	gemengd
Elman-32, backprop door de hele dienst	geleerd	geleerd	munt	gemengd	munt	munt
Elman-64, backprop door de hele dienst	gemengd	munt	gemengd	gemengd	munt	munt

Waarom de taak is afgesloten. Een test van de vraag of een netwerk capaciteit bijbouwt wanneer het aantal regels groeit, heeft een taak nodig waarop een vaste tegenstander de latere regels wél kan leren. Die is er niet. Doormeten zou tientallen keren nul opleveren en niets over structurele plasticiteit zeggen. Wat overblijft zijn drie bruikbare dingen: een tweede bevestiging van het patroon van sectie 10.5 op de regels die wél te leren zijn, een score die tegen de slimste domme speler bestand is, en een beschrijving van de manieren waarop een net hier faalt — stilvallen, gokken, steeds hetzelfde antwoord geven, en in de kalibratie ook een reflex die de voorwaarde negeert. Geen daarvan verdwijnt met een groter net: de brede Elman-variant doet het slechter dan de smalle.

10.14 Wat hierna gemeten wordt

Sectie 10.4 laat zien dat de structurele plasticiteit als geheel niets oplevert, sectie 10.5 wat de schatter kost en opbrengt, sectie 10.6 dat de leerregel eromheen op één punt zuiniger kan, en sectie 10.7 wat elk onderdeel afzonderlijk bijdraagt. De volgende versie van dit document rapporteert:

- **Elke ablatie met haar eigen leersnelheid.** De reeks van sectie 10.7 draait op één η voor alle condities, met het argument dat een ablatie de graaf verandert en niet de schaal van de update. Dat argument is redelijk maar niet gemeten. Op de twee of drie condities waar het verschil het grootst is, is een leersnelheidsveeg zoals in sectie 10.5 en 10.6 de manier om uit te sluiten dat de tabel het afstellen meet.
- **Gepoort geheugen, en een andere leerregel.** Sectie 10.13 laat zien dat een Elman-net met terugpropagatie door de hele dienst de geheugenregels van het seinhuis niet leert. Twee dingen zijn daar niet getoetst en liggen voor de hand: een net met poorten (GRU of LSTM), dat voor afhankelijkheden over tientallen stappen de gangbare oplossing is, en een schatter met minder variantie dan REINFORCE met een lopende basislijn — een criticus die op de toestand van het recurrente net zelf leert in plaats van op de zintuigen. Pas als een van beide de geheugenregels leert, heeft de vraag of ANG daar capaciteit voor bijbouwt een tegenstander.
- **Een raster van dichtheid tegen aantal neuronen.** De vraag waar dit werk uit voortkomt is wanneer een netwerk te klein is om het patroon te leren en wanneer het groot genoeg is om de trainingswerelden uit het hoofd te leren. Met de benchmarkset als toets en de structuurmaten ernaast is dat een kromme die op dit systeem te tekenen valt, en niet alleen te vermoeden.
- **Een omslag die dieper snijdt, of een uitgeleerd plateau.** Sectie 10.11 laat twee openingen. De hersteltijd van alle vier de aansturingen ligt rond de dertig pogingen en geen enkel leven is gecensureerd, dus er is weinig ruimte waarin een herstelvoordeel zichtbaar zou kunnen worden; een zwaardere omslag of een fase die lang genoeg duurt om uit te leren vergroot die ruimte. En de detector ziet de terugslag naar de zichtbare taak wel maar de overgang naar het knipperende doel niet, omdat een kanaal dat naar nul zakt minder opvalt dan een kanaal dat uit stilstand omhoogspringt. Een detector die ook een afname in spreiding meeweegt zou beide omslagen zien, en pas dan is de aansturing bij allebei getoetst.
- **Structuurmaten die wél bewegen.** Sectie 10.10 laat zien dat verscheidene maten uit sectie 6 over alle gemeten runs heen constant zijn: zij variëren niet met de taak en niet met het zaad. Zulke

maten kunnen per definitie geen gedrag verklaren. Wat dit werk nodig heeft is een beschrijving van de gevormde structuur die onder omgevingsdruk wél uiteenloopt — en het eerlijkste startpunt daarvoor is niet nog een telling, maar een interventie maat in de geest van de blinderingsproef: verstoor een deel van de graaf en meet wat het gedrag verliest.

10.15 De onderzoeksvraag, smaller gemaakt

Dit document is begonnen met de vraag of een netwerk zonder lagen en zonder backpropagation beter kan zijn dan een vast netwerk. Zes meetreeksen later is die vraag beantwoord, en het antwoord is nee. De graaf voegt op deze taak niets toe aan de leerregel (10.4). Lokaal leren kost meer dan twintig procentpunt en ongeveer een factor veertig aan rekenwerk (10.5). Geen enkel structureel mechanisme draagt afzonderlijk aantoonbaar bij (10.7). Zodra de omgeving deels waarneembaar wordt verliest de vrije graaf méér dan diezelfde graaf bevroren (10.8). En wanneer de omgeving halverwege het leven omslaat — de enige opzet waarin verbouwen tijdens het leren iets kán opleveren — herstelt de vrije graaf niet sneller dan de bevroren (10.9). Wat dit werk onderscheidt van een reeks tegenvallers is dat de voor de hand liggende oorzaak niet alleen is aangewezen maar ook is weggenomen. De herstructurering wordt aangestuurd door een klok, en waar zij wél op een signaal reageert is dat de stagnatie van het eigen leren en niet een verandering in de omgeving (10.10). Sectie 10.11 vervangt die klok door een detector op de invoerstatistiek en draait de omslagproef onveranderd opnieuw. De poort ziet de terugslag dan binnen een handvol pogingen en verbouwt daar vele malen intensiever dan elders — en het herstel verandert er niet van, ook niet tegen een klok met precies dezelfde hoeveelheid herstructurering. De negatieve bevinding is daarmee niet aan die ene ontwerpkeuze toe te schrijven. Dat is een ongemakkelijker uitkomst dan de omgekeerde zou zijn geweest, en een sterkere: de conclusie rust op een getoetste oorzaak in plaats van op een aangewezen correlatie. De vraag die overblijft is geen vergelijkingsvraag maar een grensvraag: onder welke omgevingsdruk, en onder welke aansturing, betaalt structurele plasticiteit binnen één leven zich terug ten opzichte van dezelfde graaf met bevroren structuur? Dit document levert daar vier dingen voor. Een systeem waarvan elke schroef gecontroleerd is, tot en met de numerieke controle van de leerregel zelf. Twee meetinstrumenten die losstaan van dit model en op elke architectuur werken: de blinderingsproef voor geheugen en de omslagproef voor aanpassing. Een mechanismeresultaat dat wél staat — het typesysteem draagt de geheugenhorizon (10.8). En een oorzaak die is getoetst en daarbij is uitgesloten, wat de grens waar dit document over gaat een stuk scherper trekt dan een vermoeden dat zou doen.

11 Conclusie

ANG laat zien dat de laagstructuur van een neurale netwerk opgegeven kan worden zonder dat er iets voor in de plaats hoeft te komen wat even star is. Wat overblijft is een getypeerde graaf met vijf invarianten, een leerregel die volledig uit lokale grootheden is opgebouwd, en een herstructureringsprocedure die de topologie en zelfs de soort van een neuron laat volgen uit wat er feitelijk gegroeid is. Drie begrenzings — niet abrupt, niet oneindig, en vervagend — vervangen de rol die een expliciete optimalisator in een gelaagd netwerk speelt.

De prijs is bekend: een gradiëntschatter met variantie, geen convergentiegarantie, en een gevoeligheid voor parameters die in een gelaagd netwerk niet bestaat. De winst is dat de uitkomst afleesbaar is. Aan het einde van een run staat er geen gewichtsmatrix maar een structuur, met een kortste pad, met lussen, met reflexbogen, met zintuigen die gebruikt worden en zintuigen die genegeerd worden. Voor de vraag waar dit werk uit voortkomt — begrijpen waarom een te klein of slecht getraind netwerk faalt — is dat precies de vorm waarin je een antwoord wilt hebben.

Wat het model op deze taak niet laat zien, hoort er even hard bij. Een vaste stapel lagen met dezelfde leerregel en hetzelfde parameterbudget scoort binnen de meetruis gelijk (sectie 10.4), en de structurele plasticiteit als geheel levert niets aantoonbaars op. De prestatie is dus toe te schrijven aan de leerregel, niet aan de graaf. Dat is geen weerlegging van het idee, maar het bepaalt wel waar het

bewijs vandaan moet komen: uit een omgeving waarin korte en lange paden allebei nodig zijn, niet uit een taak waarin het doel altijd zichtbaar is en één tussenlaag volstaat. Zolang die meting er niet is, is de afleesbaarheid de bijdrage en niet de prestatie.

En de prijs van lokaal leren is nu geteld. Sectie 10.5 laat zien dat de exacte gradiënt op elk van de drie gelaagde netten een verschil van meer dan twintig procentpunt maakt, en dat een netwerk van 320 gewichten dat terugpropageert de benchmarkscore van de wolk haalt voor ongeveer een 41e deel van het rekenwerk. Node-perturbatie compenseert dat met capaciteit: ongeveer een orde van grootte meer parameters om hetzelfde te halen. Wat een lokale leerregel oplevert — een update die alleen grootheden gebruikt die op de synaps zelf beschikbaar zijn — moet dus opwegen tegen die rekening, en op deze taak doet het dat niet. De verdedigbare aanspraak van ANG ligt daarmee niet bij efficiëntie, en dat is precies de afbakening die sectie 10.15 maakt.

Eén ding is de leerregel wél waard gebleken. Van de vier standaardingrepen die in sectie 10.6 zijn gemeten, doet de meest voor de hand liggende — een geleerde, toestandsafhankelijke basislijn — niets, en herstelt de schaalcorrectie uit sectie 3.11 niets. Wat wél werkt is de goedkoopste: per tik nog maar een kwart van de wolk verstoren haalt dezelfde eindscore met een factor 1.4 minder ervaring. Voor een leerregel die zichzelf verdedigt met lokaliteit en online leren is dat de relevante as: niet waar zij uiteindelijk uitkomt, maar hoeveel ervaring zij daarvoor nodig heeft. Dat is ook de as waarop de tweede taak haar zal moeten meten.

En per onderdeel is de rekening opgemaakt. De ablatiereeks in sectie 10.7 haalt er één onderdeel tegelijk uit — de drie gespecialiseerde soorten neuronen, de vier vormen van structurele plasticiteit, de bedradingsgrammatica — en meet wat dat kost. Na correctie voor negen vergelijkingen blijft er precies één onderdeel over dat aantoonbaar iets uitmaakt; de rest valt binnen de ruis. Dat is een hard resultaat over dit spel en een zacht resultaat over het model: in een omgeving waarin het doel altijd zichtbaar is en niets binnen één tik beantwoord hoeft te worden, hebben geheugen en reflex per constructie niets te doen. De ablaties krijgen pas betekenis op een taak waarin de twee tijdschalen werkelijk allebei nodig zijn, en dat is precies wat de tweede taak moet leveren.

En de laatste aanspraak is nu ook gemeten. Wat een vaste architectuur principieel niet heeft, is de mogelijkheid haar rekenstructuur te verbouwen terwijl het leven doorloopt. Sectie 10.9 zet daar één doorlopend leven tegenover waarin de omgeving twee keer omslaat, en de vrije graaf herstelt niet sneller dan dezelfde graaf bevroren (26,8 tegen 32,4 pogingen). Daarmee is de negatieve bevinding compleet: niet in eindprestatie, niet in geheugen, niet in monsterefficiëntie en niet in aanpassingssnelheid levert deze vorm van structurele plasticiteit iets op.

Maar zij is niet alleen negatief, en dat is het verschil. Dezelfde sectie laat zien waaróm: de herstructurering piekt niet na een omslag, want zij loopt op een vaste klok — en waar zij wél op een signaal reageert, is dat de stagnatie van het eigen leren en niet een verandering in de omgeving (sectie 10.10). Een mechanisme dat de omslag niet waarneemt, kan er niet op reageren. Die diagnose lag daarmee voor de hand, en sectie 10.11 heeft haar getoetst door de klok te vervangen door een detector op de omgeving. De poort vuurt daarna bij de terugslag in alle levens en binnen een handvol pogingen, en het herstel verandert er niet van — ook niet tegen een klok met precies dezelfde hoeveelheid herstructurering. De aansturing was dus niet de verklaring. Wat dit document daarmee zegt is smaller en harder tegelijk: op deze taakfamilie betaalt structurele plasticiteit zich niet terug, en dat ligt niet aan het moment waarop er verbouwd wordt. Wat overblijft als bijdrage is dan ook niet het model maar het gereedschap eromheen — de blinderingsproef, de omslagproef, de signaalproef, en een meetopzet waarin een voorspelling eerder vastligt dan de data die haar moet weerleggen.

De tweede taak die hierboven steeds werd aangekondigd, is gebouwd — en zij kon de vraag niet dragen. Sectie 10.13 laat zien dat geen enkele architectuur in dit document — ook niet een recurrent net met terugpropagatie door de hele dienst — een regel leert die geheugen over meer dan een paar tikken vraagt. De afbakening van deze conclusie verschuift daardoor niet van "op deze taak" naar "op deze twee taken", maar krijgt er een grens bij: onder de leerregels die hier gemeten zijn, is een taak

met geheugen over tientallen tikken voor geen enkele deelnemer bereikbaar, en is het vermogen van ANG om voor zo'n taak capaciteit bij te bouwen daarmee niet te toetsen. Wat de taak wél opleverde, is voor de oorspronkelijke vraag misschien het bruikbaarste van dit hele document: een netwerk dat faalt, faalt hier niet door zijn grootte maar door een beleid dat instort, door een kortere weg die de voorwaarde negeert, of door gokken dat op begrip lijkt — en de laatste twee zijn alleen zichtbaar voor een maat die per voorwaarde beide kanten weegt.

Verklaring over het gebruik van AI-hulpmiddelen

Bij dit onderzoek is Claude (Opus 5, Anthropic) gebruikt, en niet marginaal. Het hulpmiddel staat **niet als auteur vermeld**. Dat is geen bescheidenheid maar de regel: een AI-hulpmiddel kan geen verantwoording dragen voor het werk, geen belangenverstrengeling melden en geen rechten overdragen, en kan daarom volgens COPE, de ICMJE en het beleid van arXiv geen auteur zijn. De auteur is volledig verantwoordelijk voor de inhoud van dit document, ook voor de delen die met behulp van het hulpmiddel tot stand zijn gekomen.

Waar het aan heeft bijgedragen

- **Ontwerp en implementatie.** Het model, de leerregel en de structurele plasticiteit zijn in samenspraak ontworpen: de auteur stelde het onderzoeksdoel, de eis van een laagloze graaf, de vier neuronsoorten en hun bedradingsregels vast; het hulpmiddel heeft die eisen uitgewerkt tot de formuleringen in de secties 2 tot en met 6 en tot de volledige implementatie in JavaScript.
- **Metten en analyseren.** De meetscripts, de experimentloper, de statistiek en de figuren zijn met het hulpmiddel geschreven en door het hulpmiddel uitgevoerd. Alle ruwe meetgegevens zijn weggeschreven en meegeleverd (zie hieronder), zodat elke uitspraak in dit document tot de onderliggende getallen te herleiden is.
- **Schrijven.** De tekst van dit document is door het hulpmiddel opgesteld en door de auteur inhoudelijk beoordeeld en geaccordeerd.

Wat dat betekent voor de lezer

Twee dingen. Ten eerste: de tabellen in de secties 3.5, 3.11 en 10 worden door de generator rechtstreeks uit de meetbestanden opgebouwd en niet met de hand overgetypt, juist omdat een getal dat een taalmodel uit zijn hoofd opschrijft geen meting is. Ontbreekt een meetbestand, dan zegt de betreffende sectie dat de meting nog moet gebeuren in plaats van een getal te noemen. Ten tweede: de referenties zijn inmiddels stuk voor stuk tegen de vindplaats gecontroleerd — jaargang, deel, nummer en paginabereik — omdat een bibliografie precies de plek is waar een taalmodel plausibele maar onjuiste details produceert. Waar een paginabereik niet tegen een primaire bron te controleren was, staat er geen paginabereik maar een DOI. Dat is een bewuste keuze: liever een onvolledige verwijzing die klopt dan een volledige die misschien niet klopt.

Belangenverklaring

De auteur verklaart geen concurrerende financiële of persoonlijke belangen te hebben die de in dit document gerapporteerde bevindingen hebben kunnen beïnvloeden. Er is geen externe financiering ontvangen. Anthropic, de leverancier van het gebruikte AI-hulpmiddel, heeft geen rol gehad bij de opzet van het onderzoek, de uitvoering, de analyse of het besluit tot publicatie.

Beschikbaarheid van code en gegevens

Alles wat nodig is om de cijfers in dit document na te rekenen is openbaar: github.com/spikalo/AI-testing-tool.

wat	waar
het model en de leeromgeving	brein-test.html — één bestand, geen bibliotheken, draait in de browser
de generator van dit document	paper/paper.js, met paper/mkeq.py en de figuurscripts
de meetreeksen	experimenten/runs.csv — één regel per run, met beide zaden en alle instellingen
de gradiëntcontrole	experimenten/gradcheck.csv en gradcheck*.json
de controles die de eigenschappen bewijzen	tests/ — Playwright-scripts, elk met een eigen uitkomst
de reproduceerbaarheidscontrole	experimenten/reproduceerbaarheid.json

Een run ligt volledig vast door twee getallen: het breinzaad en het wereldzaad, die beide in elk resultaatbestand staan (bijlage B). Twee runs met dezelfde zaden geven bit voor bit dezelfde leercurve, dezelfde toetsen, dezelfde structuurmaten en hetzelfde eindnetwerk — gecontroleerd, niet aangenomen. De volledige resultaatbestanden per run zijn niet meegeleverd omdat zij groot zijn en uit die twee zaden exact te reproduceren.

Referenties

- [1] Bogdan, P. A., Rowley, A. G. D., Rhodes, O., & Furber, S. B. (2018). Structural plasticity on the SpiNNaker many-core neuromorphic system. *Frontiers in Neuroscience*, 12, 434.
- [2] Chklovskii, D. B., Mel, B. W., & Svoboda, K. (2004). Cortical rewiring and information storage. *Nature*, 431(7010), 782–788.
- [3] Fiete, I. R., & Seung, H. S. (2006). Gradient learning in spiking neural networks by dynamic perturbation of conductances. *Physical Review Letters*, 97(4), 048104.
- [4] Frémaux, N., & Gerstner, W. (2016). Neuromodulated spike-timing-dependent plasticity, and theory of three-factor learning rules. *Frontiers in Neural Circuits*, 9, 85. doi:10.3389/fncir.2015.00085
- [5] Holtmaat, A., & Svoboda, K. (2009). Experience-dependent structural synaptic plasticity in the mammalian brain. *Nature Reviews Neuroscience*, 10(9), 647–658.
- [6] Izhikevich, E. M. (2007). Solving the distal reward problem through linkage of STDP and dopamine signaling. *Cerebral Cortex*, 17(10), 2443–2452.
- [7] Jaeger, H. (2001). The "echo state" approach to analysing and training recurrent neural networks (GMD Report 148). Bonn: German National Research Center for Information Technology.
- [8] Maass, W., Natschläger, T., & Markram, H. (2002). Real-time computing without stable states: a new framework for neural computation based on perturbations. *Neural Computation*, 14(11), 2531–2560.
- [9] Ng, A. Y., Harada, D., & Russell, S. (1999). Policy invariance under reward transformations: theory and application to reward shaping. *Proceedings of the Sixteenth International Conference on Machine Learning (ICML)*, 278–287. Morgan Kaufmann.
- [10] Seung, H. S. (2003). Learning in spiking neural networks by reinforcement of stochastic synaptic transmission. *Neuron*, 40(6), 1063–1073.
- [11] Stanley, K. O., & Miikkulainen, R. (2002). Evolving neural networks through augmenting topologies. *Evolutionary Computation*, 10(2), 99–127.
- [12] Sutton, R. S., & Barto, A. G. (2018). *Reinforcement Learning: An Introduction* (2e druk). MIT Press.
- [13] Williams, R. J. (1992). Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine Learning*, 8, 229–256.
- [14] Xie, S., Kirillov, A., Girshick, R., & He, K. (2019). Exploring randomly wired neural networks for image recognition. *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. doi:10.1109/ICCV.2019.00137
- [15] You, J., Leskovec, J., He, K., & Xie, S. (2020). Graph structure of neural networks. *Proceedings of the 37th International Conference on Machine Learning (ICML)*, PMLR 119, 10881–10891.

Bijlage A — Notatie

Symbool	Betekenis
V, E	knopen en gerichte verbindingen van de graaf
I, O, H	invoerknopen, uitvoerknopen, de wolk ertussen
$\kappa(v)$	de soort van knoop v
$L(\cdot, \cdot)$	toelaatbaarheidsrelatie tussen soorten
w_{ij}, b_j	gewicht van verbinding $i \rightarrow j$; bias van knoop j
u_j, x_j	netto-invoer en activatie van knoop j
$\tilde{x}_i$	presynaptische activatie: de toestand aan het begin van de laatste propagatiestap
$\bar{x}_i, \delta_i$	schone activatie en perturbatie ($= x - \bar{x}$)
p_k, a_k	kans op en uitkomst van knopdruk k
e_{ij}	eligibility trace van verbinding $i \rightarrow j$
$r_t, \bar{r}_t, \hat{A}_t$	beloning, lopende basislijn, advantage
$\varepsilon, \tau, \sigma_h$	exploratie, temperatuur van de knoppen, ruis in de wolk
η, λ, ρ	leersnelheid, sporenvervaging, vervaging per poging
φ	dempingsfactor tegen het gewichtsplafond
θ_p, n_{ij}	snoeidrempel en het aantal ronden dat $i \rightarrow j$ al zwak is
$C(i, t), S(t)$	kosten van soort t voor neuron i ; de specificiteitsbonus
$T(i), \mu$	de gekozen soort; de marge waarmee zij moet winnen
v_i	invloed van invoerknoop i op de uitvoer

Bijlage B — Het resultaatbestand

Elke afgeronde run wordt als één JSON-bestand weggeschreven. De indeling is zo gekozen dat het bestand op zichzelf voldoende is: er is geen aanvullend logboek nodig om de run te herhalen, het netwerk te hertekenen of het brein terug te laden.

veld	inhoud
versie	formaatversie van het bestand
tijdstip, spel, brein	wanneer, welke taak, welke naam
breinZaad	zaad van de startwolk — samen met het wereldzaad legt dit de run vast
config.startNeuronen, .samenstelling, .samenstellingStart	aantal en soortverdeling bij begin en einde
config.startdichtheid, .invoerAlleenViaSens	bedradingsdichtheid en de strengere invoerregel
config.types	per soort: aan/uit met minimum en maximum
config.wereld	obstakels, stappen per poging, verversing, wereldzaad, snelheid, stoppen bij botsing
config.leren	$\eta, \lambda, \rho, w_{\max}, \Delta_{\max}$, geheugenlek, propagatiediepte, exploratie begin en eind
config.structureel	ritme, snoeidrempel, aangroei, groei, soortverandering en hun grenzen
config.beloningen	doel, vooruitgang, botsing, per stap, stilstaan
config.training	pogingen, toetsen aan/uit, toetsmodus, aantal toetswerelden

veld	inhoud
resultaat	succes totaal en over de laatste twintig, toetsscore, stappen, beloning, botsingen, rekentijd
structuur	alle maten uit sectie 6, plus gesnoeid, bijgegroeid, geboren en omgetypt
historie	per poging: geslaagd, beloning, stappen, stilstaan, verbindingen, neuronen, gemiddeld gewicht
toetsen	per toetsmoment de score op de onbekende werelden
herstructureringen	per ronde wat er gesnoeid, aangegroeid, omgetypt en bijgegroeid is
netwerk.neuronen	per knoop: nummer, soort, label, positie, bias
netwerk.verbindingen	per verbinding: bron, doel, gewicht
netwerk.nextId	volgnummer voor labels van later geboren neuronen

Een reeks runs schrijft daarnaast één regel per run naar een gezamenlijke tabel met 79 kolommen: de conditienaam, beide zaden, de parameters die tussen condities kunnen verschillen, en alle uitkomst- en structuurmaten. Die tabel is de bron waaruit de tabellen in sectie 10 van dit document worden opgebouwd — niet met de hand overgetypt, maar bij elke hergeneratie opnieuw uit de meetgegevens gelezen.